

Mémoire de fin d'études présenté en vue de l'obtention du
diplôme de Master 2 ERCFCC

Amélioration de la prédiction de la volatilité
Approche croisée entre finance comportementale et Machine
Learning



Préparé par : Mr. Mehdi HACHFI

Encadré par : Mr. Fredj JAWADI

Date de soutenance : 13 Mai 2025

Table des matières

Remerciement :	4
Abstract :	5
Introduction :	6
Chapitre 1 : La volatilité financière, de l'analyse rationnelle à la dimension émotionnelle	7
1.1 La volatilité selon Robert Shiller :	7
1.2 Le rôle des émotions collectives dans la volatilité :	8
1.2.1 L'impact des émotions collectives sur la volatilité des marchés :	8
1.2.2 Le rôle des émotions dans les prévisions de la volatilité :	8
1.2.3 Structuration émotionnelle des phases de marché :	9
Chapitre 2 : Séries chronologiques, données et outils	11
2.1 Les séries chronologiques :	11
2.2 Les données :	11
2.2.1 Source des données :	11
2.2.2 Variable expliquée & variables explicatives :	12
2.3 Visualisation préliminaire	13
2.4 Corrélation :	17
2.5 Outils :	19
Chapitre 3 : Modélisation de la volatilité par des modèles économétriques	20
3.1 Modélisation de la volatilité sur la première période (1881-1990) :	20
3.1.1 Le processus ARMA(p,q) :	20
3.1.2 Le processus ARIMA(p,d,q) :	22
3.1.3 Le processus ARIMA-EGARCH :	25
3.2 Modélisation de la volatilité sur la deuxième période (1991-2024) :	28
3.2.1 Le processus ARMA(p,q) :	28
3.2.2 Le processus ARIMA(p,d,q) :	29
3.2.3 Le processus ARIMA-EGARCH :	32
3.3 Conclusion :	35
Chapitre 4 : Modélisation de la volatilité par machine learning	36
4.1 Intelligence Artificielle :	36
4.1.1 Machine Learning :	36
4.2 Modélisation de la volatilité sur la première période (1881-1990) :	37

4.2.1	Modèle Ridge :	37
4.2.2	Modèle Lasso :	40
4.2.3	Modèle ElasticNet :	42
4.2.4	Réseaux de neurones :	45
4.3	Modélisation de la volatilité sur la deuxième période (1991-2024) :	50
4.3.1	Modèle Ridge :	50
4.3.2	Modèle Lasso :	52
4.3.3	Modèle ElasticNet :	54
4.3.4	Réseaux de neurones :	54
Chapitre 5 : Comparaison des différents modèles utilisés :		59
5.1	Comparaison basée sur MSE :	59
5.2	Test de Diebold-Mariano :	59
5.3	Test de Clark & West sur la deuxième période :	61
Conclusion :		63
Ouverture :		64
Bibliographie :		65

Remerciement :

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce mémoire.

Je remercie tout d'abord Monsieur Fredj JAWADI, mon encadrant, pour sa disponibilité, ses conseils éclairés, ainsi que la rigueur et la bienveillance avec lesquelles il a suivi l'avancement de ce travail. Son expertise et ses suggestions pertinentes ont été d'une grande aide tout au long de cette recherche.

J'adresse également mes sincères remerciements à Monsieur Éric SEVERIN, responsable du Master, pour la qualité de l'enseignement dispensé, ainsi que pour son engagement dans la formation des étudiants.

Enfin, je remercie l'ensemble de l'équipe pédagogique, mes camarades de promotion, ainsi que mes proches, pour leur soutien, leur motivation et leur présence tout au long de cette année universitaire.

Abstract :

This thesis aims to improve financial market volatility forecasting by integrating behavioral and emotional variables into predictive models. The analysis is conducted over two distinct periods: the first based on traditional macroeconomic indicators, and the second enriched with investor sentiment, confidence levels, and fear indices. The study compares classical models with advanced machine learning approaches, especially neural networks with multiple hidden layers. Results show that incorporating emotional variables significantly enhances prediction accuracy, particularly in recent market regimes. Validation through performance metrics (MSE, RMSE) and statistical tests (Diebold-Mariano and Clark & West) confirms the robustness of these findings. The research concludes that market volatility is not solely driven by economic fundamentals, but is also shaped by collective emotions and investor behavior.

Introduction :

La volatilité constitue un concept central dans la théorie financière, reflétant l'incertitude ou la variabilité des rendements d'un actif financier. Sa compréhension et sa prévision jouent un rôle crucial dans de nombreux domaines, tels que la gestion des risques, la valorisation des produits dérivés, la gestion de portefeuille ou encore la réglementation bancaire. Si la volatilité est historiquement appréhendée à travers des modèles économétriques classiques, les évolutions récentes des marchés financiers ont mis en évidence les limites de ces approches dans des environnements de plus en plus complexes et instables.

En parallèle, l'émergence de nouvelles sources d'information notamment liées au comportement des investisseurs, aux émotions de marché ou encore aux indicateurs de sentiment appelle à une redéfinition des facteurs explicatifs de la volatilité. Ces dimensions, longtemps négligées, semblent aujourd'hui incontournables pour comprendre les dynamiques de marché modernes. Cette évolution pose une question centrale : les modèles classiques sont-ils encore suffisants pour anticiper les mouvements de volatilité dans un monde dominé par l'incertitude, l'instantanéité de l'information et l'émotion collective ?

Ce mémoire s'inscrit dans cette dynamique. Il se propose d'étudier la contribution potentielle des modèles de Machine Learning, et plus précisément des réseaux de neurones, à l'amélioration de la prévision de la volatilité. Pour ce faire, deux périodes distinctes sont analysées : une période historique (1881–1990), reposant sur des variables macro-financières classiques, et une période plus récente (1991–2024), intégrant des indicateurs liés au sentiment du marché et aux émotions des investisseurs.

L'objectif est double :

- Evaluer empiriquement la performance de différents modèles dans la prévision de la volatilité.
- Comprendre comment l'introduction de nouvelles variables comportementales modifie la dynamique de prédiction.

Chapitre 1 : La volatilité financière, de l'analyse rationnelle à la dimension émotionnelle

La volatilité est une mesure fondamentale de la variabilité des prix sur les marchés financiers. Elle renseigne sur l'incertitude qui entoure les anticipations des investisseurs, la stabilité des rendements et la perception du risque. Ce chapitre introductif vise à poser les bases théoriques et comportementales autour de cette notion. Pour ce faire, nous nous appuyons principalement sur :

- Le livre de référence « Market Volatility » de Robert J. Shiller,
- Les deux articles :
 - « Can Collective Emotions Improve Bitcoin Volatility Forecasts? »
 - « Do collective emotions drive bitcoin volatility? A triple regime-switching vector approach »,
de David Bourghelle, Fredj Jawadi et Philippe Rozin.
 - « How emotional is the stock market? An empirical analysis », de Vineet Agarwal, Richard J. Taffler et Chenyang Wang.

1.1 La volatilité selon Robert Shiller :

Dans Market Volatility, Robert Shiller remet en question la théorie des marchés efficients, en montrant que les fluctuations des prix des actifs, notamment des actions, excèdent largement ce que les fondamentaux économiques peuvent expliquer. Selon lui, cette volatilité excessive est révélatrice de comportements irrationnels et d'une forte dimension psychologique sur les marchés financiers.

Dans le cadre standard, le prix d'un actif P_t est censé refléter la valeur actualisée de ses dividendes futurs espérés D_{t+i} :

$$P_t = \sum_{i=1}^{\infty} \frac{E_t[D_{t+i}]}{(1+r)^i}$$

Or, Shiller montre que la volatilité empirique de P_t oscille autour sa composante fondamentale. Donc le prix observé fluctue autour de sa valeur fondamentale P_t^* , avec une composante d'écart ε_t liée aux comportements de marché :

$$P_t = P_t^* + \varepsilon_t$$
$$Var(P_t) > Var(P_t^*)$$

Le terme ε_t engendre plusieurs mécanismes :

- Les anticipations instables des agents, influencées par des biais cognitifs ;
- Les effets de mode ou de panique (généralement les sentiments) ;
- L'influence des récits économiques, formalisée par l'approche dite de narrative economics (media).

Dans cette perspective, la volatilité n'est pas uniquement la conséquence d'un bruit aléatoire autour des fondamentaux, mais le reflet de dynamiques collectives. Shiller invite ainsi à dépasser les modèles purement rationnels et à intégrer les dimensions cognitives et émotionnelles dans l'analyse des marchés financiers.[1]

1.2 Le rôle des émotions collectives dans la volatilité :

1.2.1 L'impact des émotions collectives sur la volatilité des marchés :

L'impact des émotions collectives sur la dynamique des prix financiers a fait l'objet d'un intérêt croissant dans la littérature récente. Les émotions (telles que la peur, l'euphorie, l'anxiété ou l'excitation) influencent profondément le comportement des investisseurs, particulièrement dans des contextes d'incertitude élevée ou de mouvements extrêmes de marché.

L'article « Do collective emotions drive Bitcoin volatility? » publié dans le Journal of Economic Behavior & Organization illustre parfaitement cette approche comportementale. Les auteurs y étudient l'effet des émotions collectives sur la volatilité du Bitcoin durant la période 2018–2021, en mobilisant un modèle économétrique par un vecteur de deux équations non-linéaire autorégressif avancé à (VAR).

Les résultats obtenus, bien qu'ancrés dans le contexte du Bitcoin, mettent en lumière des mécanismes génériques applicables à d'autres actifs financiers :

- Les émotions influencent la volatilité et sont en retour amplifiées par elle. Cette interdépendance souligne l'existence d'une boucle de rétroaction entre psychologie collective et dynamique des prix.
- Durant les périodes calmes, un climat émotionnel positif peut stabiliser les marchés. En revanche, en situation de bulle ou de stress, une hausse de la confiance ou de la peur peut accroître la prise de risque ou provoquer des réactions paniques, ce qui intensifie la volatilité.
- Les effets des émotions ne sont pas symétriques. Par exemple, une augmentation de la peur provoque généralement une plus forte volatilité que le même niveau d'euphorie ne fait pas même chose au niveau de réduction.

Cette analyse souligne que les marchés financiers ne sont pas gouvernés uniquement par des données objectives et des arbitrages rationnels. Ils sont également façonnés par l'état émotionnel collectif des acteurs, qui peut déstabiliser les prix de manière significative.[2]

1.2.2 Le rôle des émotions dans les prévisions de la volatilité :

L'article « Can Collective Emotions Improve Bitcoin Volatility Forecasts? » approfondit l'analyse du lien entre émotions collectives et volatilité des marchés, en explorant non seulement leur interaction, mais aussi leur valeur prédictive. Les auteurs étendent leur approche précédente en étudiant dans quelle mesure les émotions collectives peuvent améliorer la capacité de prévision de la volatilité du Bitcoin.

Les résultats obtenus, bien qu'ancrés dans le contexte du Bitcoin, mettent en lumière des mécanismes génériques applicables à d'autres actifs financiers :

- Les émotions améliorent la prévision de la volatilité : les modèles enrichis par les émotions obtiennent de meilleures performances.
- Les émotions sont plus informatives dans les régimes instables, comme les phases de bulle ou d'effondrement. En revanche, leur apport est plus limité en période calme.

- Les émotions négatives sont particulièrement prédictives : la peur, la colère et la tristesse sont plus fortement associées à des hausses futures de la volatilité que les émotions positives ne le sont à sa baisse.

Cette étude confirme que les émotions collectives peuvent être utilisées de manière proactive dans la prévision de la volatilité, et pas seulement comme variables d'explication a posteriori. Cela ouvre la voie à une nouvelle génération de modèles qui, en intégrant des dimensions psychologiques, deviennent plus réactifs aux signaux faibles et aux dynamiques comportementales.[3]

1.2.3 Structuration émotionnelle des phases de marché :

L'article « How emotional is the stock market? An empirical analysis », propose une lecture innovante du comportement des marchés financiers en étudiant leur structuration autour d'émotions collectives dominantes. Plutôt que de considérer les émotions comme des phénomènes ponctuels ou aléatoires, les auteurs montrent qu'elles peuvent structurer durablement certaines phases de marché.

À partir de données de marché combinées à des indicateurs de sentiment, l'étude identifie plusieurs régimes émotionnels, caractérisés chacun par une émotion dominante : euphorie, confiance, anxiété ou peur. Ces régimes sont extraits de séries temporelles à l'aide de méthodes de classification non supervisées, qui révèlent une structure émotionnelle sous-jacente aux dynamiques de marché.

Les principaux résultats mettent en évidence que :

- Chaque phase de marché est associée à une émotion collective dominante, ce qui permet de relier les fluctuations des prix à des états psychologiques collectifs spécifiques ;
- Ces émotions agissent directement sur les décisions d'investissement : l'euphorie tend à favoriser les achats impulsifs et la formation de bulles, tandis que la peur déclenche des ventes massives et des comportements de fuite vers la qualité ;
- La volatilité est significativement plus élevée dans les régimes émotionnels négatifs, comme la peur ou l'anxiété, que dans les régimes de confiance ou de stabilité.[4]

Cela est bien schématisé dans la figure suivante :




Figure 1 : Structuration des émotions

Ces convergent vers une lecture élargie de la volatilité. Elle ne peut être comprise uniquement comme une résultante mécanique de l'information économique. Elle est aussi le reflet des dynamiques collectives, des récits médiatiques, des incertitudes, et des émotions qui traversent les marchés.

Cela implique :

- De prendre en compte les émotions dans les outils d'analyse financière ;
- D'identifier les régimes émotionnels dominants pour mieux comprendre les mouvements de marché ;
- De considérer l'investisseur non comme un agent purement rationnel, mais comme un être influencé par des biais cognitifs et émotionnels.

Cette approche comportementale et émotionnelle de la volatilité fonde le reste de ce mémoire, qui vise à étudier empiriquement dans quelle mesure l'intégration de variables liées au sentiment et aux émotions permet d'améliorer la prévision de la volatilité.

Chapitre 2 : Séries chronologiques, données et outils

2.1 Les séries chronologiques :

Une série chronologique est une succession des observations au cours du temps, peut être notée $(X_t, t = 1, \dots, T)$. t représente le temps, et X_t est une variable aléatoire modélisant la variable étudiée au temps t .

L'étude des séries chronologiques sert à analyser, décrire et expliquer un phénomène au cours du temps, pour prévoir les valeurs futures de la variable étudiée à partir des valeurs observées.

Cela se fait en enchaînant les étapes suivantes :

- Nettoyage des données : Cela consiste à s'occuper des données manquantes ou erronées. On peut, par exemple, remplacer les valeurs manquantes ou corriger celles qui semblent incohérentes. Ensuite, sur l'application des transformations, comme la méthode de Box-Cox ou le logarithme, pour rendre la variance stable (les données plus stables et plus faciles à analyser).
- Étude de la série : Avant de faire quoi que ce soit, on regarde le graphique de la série de données pour comprendre sa structure. Cela inclut l'identification des tendances générales, des cycles et des variations saisonnières. Cette étape aide à choisir le bon type de modèle à utiliser.
- Création d'un modèle : on choisit et construit un modèle qui correspond à la série de données. Il existe deux grandes catégories de modèles :
 1. Modèles déterministes : Ces modèles suivent une structure fixe, comme une tendance linéaire ou une saisonnalité régulière.
 2. Modèles stochastiques : Ces modèles prennent en compte les incertitudes et les variations aléatoires dans les données.
- Validation et utilisation du modèle : Une fois le modèle créé, on vérifie s'il fonctionne bien en le testant avec des données. Si le modèle est satisfaisant, on l'utilise pour faire des prévisions ou répondre à des questions spécifiques.

2.2 Les données :

Dans cette étude, nous analysons la volatilité des marchés financiers sur deux périodes distinctes : 1881–1990 et 1991–2024. Pour chaque période, différentes variables explicatives sont utilisées, en fonction de leur disponibilité historique et de leur pertinence économique.

2.2.1 Source des données :

- Période 1881–1990 :

Pour la première période, les variables suivantes ont été utilisées :

- Rendement des actions
- Taux d'intérêt
- Taux de croissance des dividendes

Ces variables ont été calculées à partir de la base de données historique de Robert Shiller, largement reconnue pour la qualité et la profondeur de ses séries financières longues (notamment les données mensuelles sur le marché boursier américain).

- Période 1991–2024

Pour la deuxième période, nous avons enrichi l'analyse avec des indicateurs reflétant le climat émotionnel et psychologique des marchés. Les variables utilisées sont :

- Rendement des actions
- Taux d'intérêt
- Taux de croissance des dividendes
- Indice de volatilité implicite VIX (également appelé "indice de la peur")
- Sentiment de l'investisseur
- Taux de change dollar américain / euro

Les données relatives au VIX, au sentiment de l'investisseur ainsi qu'au taux de change dollar/euro ont été obtenues à partir de la base de données économique de la Federal Reserve Bank of St. Louis (FRED).

2.2.2 Variable expliquée & variables explicatives :

- Variable expliquée :

Volatilité : Une mesure de la variation des prix calculée sur une période glissante de 12 mois, à l'aide de l'écart-type :

$$Volatilité_t = \sqrt{Var.S(Rendement \text{ sur les } 12 \text{ derniers mois})}$$

- Variables explicatives :

Date : Une série temporelle mensuelle, chaque ligne correspondant à la fin du mois.

Taux de croissance de dividende : mesure l'augmentation des dividendes d'une entreprise sur une période donnée.

$$DividendGrowthRate_t = \left(\frac{Dividend_t}{Dividend_{t-1}} \right) - 1$$

$Dividend_t$: dividende de l'année actuelle

$Dividend_{t-1}$: dividende de l'année précédente

Rendement (Yield) : mesure le revenu généré par un investissement par rapport à son coût ou à sa valeur actuelle. Calculé comme suit :

$$Rendement_t = \log\left(\frac{Prix_t}{Prix_{t-1}}\right)$$

Ce calcul permet de normaliser les rendements pour des analyses économétriques et des modèles stochastiques.

Taux d'intérêt (InterestRate) : le rendement d'un placement (base de données de Robert Shiller).

Indice de volatilité implicite VIX : Le VIX, souvent appelé "indice de la peur", mesure la volatilité implicite des options sur l'indice S&P 500. Il reflète les anticipations du marché

quant à la volatilité future à court terme et sert d'indicateur de l'incertitude ou du stress des investisseurs.

Sentiment de l'investisseur : Le sentiment de l'investisseur traduit l'état psychologique des agents de marché (optimisme, pessimisme). Il est généralement construit à partir d'enquêtes ou d'analyses textuelles, et permet de capter l'impact des émotions collectives sur les mouvements de marché.

Taux de change dollar américain / euro : Ce taux de change reflète la valeur du dollar américain par rapport à l'euro.

Par la suite, la base de données va être multiplier par 100.

2.3 Visualisation préliminaire

- a- Rendement : la figure ci-dessous illustre l'évolution du rendement des prix pour les deux périodes (de Janvier 1881 à Décembre 1990 et de Janvier 1991 à Septembre 2024).





Figure 2 : Graphes du rendement sur les deux périodes

On remarque une stabilité globale, La majorité des rendements sont centrés autour de zéro, indiquant une performance globalement stable sur le long terme, mais il y a présence des bulles spéculatives dans certaines périodes, et cela revient à des crises financières.

b- Taux d'intérêt : La figure ci-dessous illustre l'évolution du taux d'intérêt sur les deux périodes du temps étudiées

Évolution du taux d'intérêt (Janvier 1881 - Décembre 1990)



Évolution du taux d'intérêt (Janvier 1991 - Septembre 2024)




Figure 3 : Graphes du taux d'intérêt sur les deux périodes

c- Taux de croissance de dividende : La figure ci-dessous illustre l'évolution du taux de croissance de dividende sur les deux périodes du temps étudiées.




Figure 4 : Graphes du taux de croissance sur les deux périodes

- d- VIX (l'indice de la peur) : La figure ci-dessous illustre l'évolution de l'indice de la peur sur la deuxième période du temps étudié.




Figure 5 : Evolution de l'indice de la peur sur la période 2

- e- Emotion (l'indice d'émotion) : La figure ci-dessous illustre l'évolution de l'indice d'émotion sur la deuxième période du temps étudié.

Évolution de l'indice d'Emotion (Janvier 1991 - Septembre 2024)




Figure 6 : Evolution de l'indice d'émotions sur la période 2

- f- **Confidence** (l'indice de confiance) : La figure ci-dessous illustre l'évolution de l'indice de confiance sur la deuxième période du temps étudié.

Évolution de l'indice de Confiance (Janvier 1991 - Septembre 2024)




Figure 7 : Evolution de l'indice de confiance sur la période 2

- g- **Volatilité** : La figure ci-dessous illustre l'évolution de la volatilité sur les deux périodes du temps étudiées.




Figure 8 : Graphes de la volatilité sur les deux périodes

2.4 Corrélation :

- Période 1 : Janvier 1881 – Décembre 1990

Janvier 1881 - Décembre 1990				
	DividendGrowthRate	InterestRate	Yield	Volatility
DividendGrowthRate	1.00	-0.04	0.09	-0.19
InterestRate		1.00	-0.04	-0.06
Yield			1.00	-0.02
Volatility				1.00

Figure 9 : Matrice de corrélation de la période 1

La volatilité est faiblement corrélée avec toutes les autres variables :

- Légèrement négative avec le taux de croissance des dividendes (-0.19)
- Corrélations quasi nulles avec les taux d'intérêt (-0.06) et le rendement (-0.02)
- DividendGrowthRate n'est pas corrélé aux autres variables (corrélations très faibles)
- InterestRate et Yield ne présentent pas de relation significative (-0.04 entre eux)

Durant la période 1881–1990, aucune relation forte n'est observée entre la volatilité et les variables économiques considérées. Cela suggère que la volatilité était probablement influencée par d'autres facteurs plus complexes (non linéaires).

- Période 2 : Janvier 1991 – Septembre 2024

Janvier 1991 - Septembre 2024							
	DividendGrowthRate	InterestRate	Yield	VIX	Emotion	Confidence	Volatility
DividendGrowthRate	1.00	-0.19	-0.01	-0.25	0.06	0.07	-0.43
InterestRate		1.00	0.00	-0.14	-0.11	0.38	-0.26
Yield			1.00	-0.39	-0.20	0.09	-0.04
VIX				1.00	0.22	-0.28	0.67
Emotion					1.00	0.18	0.15
Confidence						1.00	-0.37
Volatility							1.00

Figure 10 : Matrice de corrélation de la période 2

La volatilité est :

- Fortement corrélée positivement au VIX (+0.67), ce qui est attendu puisque le VIX est un indicateur anticipé de la volatilité.
- Corrélée négativement au taux de croissance des dividendes (-0.43) et à la confiance des investisseurs (-0.37). Une baisse de la confiance ou une croissance faible est donc associée à une hausse de la volatilité.
- Faiblement corrélée à l'émotion (+0.15) et aux taux d'intérêt (-0.26).
- La confiance est positivement liée aux taux d'intérêt (+0.38), ce qui peut refléter un contexte économique perçu comme plus favorable lors des hausses de taux.
- L'émotion et le VIX présentent une corrélation faible (+0.22), suggérant que l'intensité émotionnelle perçue ne coïncide pas toujours avec la volatilité anticipée.

L'analyse comparative des deux périodes met en évidence une évolution notable des déterminants de la volatilité.

Durant la période 1881–1990, la volatilité présente une faible corrélation avec l'ensemble des variables économiques, à l'exception d'un lien modéré avec le taux de croissance des dividendes. Cela suggère une influence limitée des facteurs macroéconomiques classiques sur la volatilité durant cette période.

En revanche, pour la période 1991–2024, la volatilité devient significativement corrélée à des variables reflétant le climat psychologique et émotionnel du marché, notamment le VIX (corrélation de +0.67) et la confiance des investisseurs (corrélation de -0.37). Les taux d'intérêt montrent également une influence plus marquée (-0.26). Ces résultats traduisent un changement de dynamique : la volatilité semble désormais davantage guidée par les anticipations, les perceptions et les émotions du marché, en plus des conditions économiques.

Cette évolution reflète un environnement financier devenu plus sensible aux signaux émotionnels et aux décisions de politique monétaire, rendant les marchés plus réactifs aux changements de contexte économique et psychologique.

2.5 Outils :

RStudio est un environnement de programmation et un langage largement utilisé pour la statistique et l'analyse de données. Il est particulièrement adapté pour la modélisation statistique, les analyses de séries temporelles et le machine learning. RStudio offre une large gamme de bibliothèques qui permettent de réaliser des analyses complexes, de construire des modèles prédictifs et d'effectuer des tests statistiques. Ce qui pousse à l'utiliser dans tout le mémoire, en faisant appui sur les modèles suivants :

- ARIMA (Moyenne mobile intégrée autorégressive)
- EGARCH (Hétéroscédasticité conditionnelle autorégressive généralisée) :
- Ridge
- Lasso (opérateur de sélection et de rétrécissement absolu minimal) :
- ElasticNet
- Réseaux de Neurones

Chapitre 3 : Modélisation de la volatilité par des modèles économétriques

3.1 Modélisation de la volatilité sur la première période (1881-1990) :

3.1.1 Le processus ARMA(p,q) :

Les modèles ARMA (AutoRegressive Moving Average) sont des outils mathématiques utilisés pour analyser et prévoir des séries temporelles, c'est-à-dire des données mesurées au fil du temps. Ils ont été développés par George Box et Gwilym Jenkins et sont souvent appelés la méthode de Box-Jenkins.

Un modèle ARMA combine deux types de modèles :

3.1.1.1 Les modèles AR(p) (AutoRégressifs) :

Les modèles AR(p) (AutoRégressifs) : Ils utilisent les valeurs passées d'une série pour prévoir sa valeur actuelle. Par exemple, on estime une donnée à partir de ses données précédentes, avec un calcul basé sur des coefficients spécifiques, et il prend la forme suivante :

$$X_t = a_1 * X_{t-1} + a_2 * X_{t-2} + \dots + a_p * X_{t-p} + \varepsilon_t$$

Avec ε_t un bruit blanc.

Le processus autorégressif (AR) tire son nom de sa similarité avec le modèle de régression multiple. Cependant, au lieu de prédire une variable en fonction d'autres variables, il s'agit ici de prédire la valeur actuelle X_t d'une série en fonction de ses propres valeurs passées. C'est de là que vient le terme "autorégression".

3.1.1.2 Les modèles MA(q) (Moyenne Mobile) :

Les modèles MA(q) (Moyenne Mobile) : Ils prennent en compte les erreurs (ou fluctuations imprévues) des périodes précédentes pour estimer la valeur actuelle. Il est représenté comme une moyenne mobile d'ordre q, et il s'écrit sous la forme suivante :

$$X_t = \varepsilon_t + b_1 * \varepsilon_{t-1} + b_2 * \varepsilon_{t-2} + \dots + b_q * \varepsilon_{t-q}$$

Avec ε_t un bruit blanc.

3.1.1.3 ARMA(p,q)

En combinant ces deux approches, le modèle ARMA permet de mieux comprendre et prévoir des séries temporelles qui sont stationnaires, c'est-à-dire dont les propriétés, comme la moyenne et la variance, ne changent pas avec le temps.

Une série X_t est appelée ARMA(p,q), s'elle s'écrit sous la forme suivante :

$$X_t = a_1 * X_{t-1} + a_2 * X_{t-2} + \dots + a_p * X_{t-p} + \varepsilon_t + b_1 * \varepsilon_{t-1} + b_2 * \varepsilon_{t-2} + \dots + b_q * \varepsilon_{t-q}$$

3.1.1.3.1 Détermination du p et q :

Le choix de l'ordre d'un modèle mixte $ARMA(p,q)$ repose sur l'analyse des deux fonctions suivantes :

- ACF (Autocorrelation Function) : Elle mesure la corrélation entre une série et ses décalages successifs (lags). Elle est utilisée pour identifier la partie MA (Moving Average) du modèle. Si l'ACF diminue rapidement après un certain décalage, cela peut indiquer l'ordre q .
- PACF (Partial Autocorrelation Function) : Elle mesure la corrélation entre une série et ses décalages, en éliminant l'effet des corrélations intermédiaires. Elle est utile pour identifier la partie AR (AutoRégressive) du modèle. Si la PACF décroît nettement après un certain décalage, cela peut indiquer l'ordre p .

3.1.1.3.2 Application :

- Détermination de l'ordre p de AR par la fonction PACF, on obtient le résultat suivant :

PACF de la Volatilité 1881-1990




Figure 11 : PACF de la série de la volatilité de la période 1

La fonction PACF s'annule à partir du Lag 2, donc p égale 2 (AR(2)).

- Détermination de l'ordre q se fait à partir du graphe de la fonction ACF, on obtient le résultat suivant :

ACF de la Volatilité 1881-1990




Figure 12 : ACF de la série de la volatilité de la période 1

La fonction ACF (fonction d'autocorrélation) décroît lentement, cela suggère que la série temporelle peut avoir une dépendance à long terme, ce qui peut être un signe que la série n'est pas stationnaire. Dans ce cas, il est en effet plus approprié d'utiliser un modèle

ARIMA (AutoRegressive Integrated Moving Average), qui intègre une composante de différenciation pour rendre la série stationnaire.

3.1.2 Le processus ARIMA(p,d,q) :

3.1.2.1 Le modèle à utiliser :

Le processus ARIMA(p,d,q) est un processus ARMA(p,q) de moyenne nulle intégré d fois. Après la première dérivation, le graphe de la volatilité devient :




Figure 13 : Graphes de la dérivée de la volatilité sur la période 1
A partir de ce graphe on dit que le dérivé de la série de la volatilité est stationnaire (d=1).
On trace les deux fonction ACF et PACF pour déterminer p et q :




Figure 14 : PACF de la dérivée de la volatilité sur la période 1
A partir de ce graphe, on conclut que p=1.




Figure 15 : ACF de la dérivée de la volatilité sur la période 1

A partir de ce graphe, on conclut que $q=2$.

Donc pour estimer la volatilité, le modèle à utiliser est : ARIMA(1,1,2), qui s'écrit comme suit :

$$Volatility' = a_1 * Volatility'_{-1} + b_1 * \varepsilon_{-1} + b_2 * \varepsilon_{-2}$$

Volatility' est la dérivée de Volatility.

3.1.2.2 Prédiction par ARIMA(1,1,2) :

Coefficients ARIMA(1,1,2) :

```
arima(x = train1, order = c(1, 1, 2))

Coefficients:
      ar1      ma1      ma2
    -0.8732  -0.1394  -0.8606
s.e.    0.1278   0.1331   0.1331

sigma^2 estimated as 2.84:  log likelihood = -2051.08,  aic = 4110.15
```

Figure 16 : Coefficients du modèles ARIMA(1,1,2)

- AR(1) = -0.8732 (avec une erreur standard de 0.1278)
- Le coefficient AR(1) représente la dépendance entre l'observation actuelle et l'observation précédente. Ici, une valeur de -0, 8732 indique une légère autocorrélation négative entre les observations successives.
- MA(1) = -0.1394 (avec une erreur standard de 0.1331)
- Le coefficient MA(1) est négatif (-0.1394), indiquant qu'il y a une faible relation inverse entre l'erreur à 1 période précédente et l'observation actuelle
- MA(2) = -0.8606 (avec une erreur standard de 0.1331)
- Le coefficient MA(2) est positif (0.2334), indiquant une relation négative avec l'erreur à 2 périodes passées.

3.1.2.3 Validation du modèle :

La fonction `checkresiduals()` du package `forecastest` utilisée pour analyser les résidus d'un modèle de série temporelle, comme pour notre modèle ARIMA(1,1,2). Les résidus représentent la différence entre les valeurs enregistrées et les valeurs prédites.




Figure 17 : Présentation des résidus du modèle ARIMA(1,1,2)

Autocorrélation des résidus (ACF) : L'analyse de l'autocorrélation des résidus, représentée par la fonction d'autocorrélation (ACF), montre que certaines valeurs d'ACF sortent de la plage proche de zéro (entre -0.05 et 0.05). Cela suggère qu'il y a une corrélation significative dans les résidus du modèle.

Normalité des résidus : Le test de la normalité des résidus révèle que ceux-ci suivent une distribution normale, comme l'indique le test de normalité et la visualisation des résidus. Cela confirme que les erreurs du modèle sont distribuées normalement, ce qui est une hypothèse sous-jacente importante pour la validation du modèles ARIMA(1,1,2) sur la première période.

Test de Ljung-Box des résidus : Le test de Ljung-Box a été effectué pour vérifier l'indépendance des résidus du modèle ARIMA(1,1,2). L'hypothèse nulle du test est que les résidus sont indépendants (absence d'autocorrélation), et l'hypothèse alternative est que les résidus présentent une autocorrélation significative.

```
> checkresiduals(modelARIMA1)

Ljung-Box test

data: Residuals from ARIMA(1,1,2)
Q* = 15.762, df = 7, p-value = 0.02738

Model df: 3. Total lags used: 10
```

Figure 18 : Test de Ljung-Box des résidus du modèle ARIMA(1,1,2)

Résultats du test :

- Q = 15.762

- $df = 7$ (degrés de liberté)
- $p\text{-valeur} = 0,02438$

La valeur p du test de Ljung-Box est de 0,02438, ce qui est inférieur au seuil de significativité standard de 0,05. Cela signifie que nous rejetons l'hypothèse nulle selon laquelle les résidus sont indépendants. Autrement dit, les résultats du test suggèrent qu'il y a une autocorrélation significative dans les résidus du modèle ARIMA(1,1,2). Cela baisse la fiabilité du modèle ARIMA(1,1,2) sur la première période.

3.1.2.4 Estimer par le modèle ARIMA(1,1,2) :

- MSE (erreur quadratique moyenne) = 0,000427. Cela indique que la moyenne des carrés des erreurs est assez petite, ce qui signifie que le modèle ARIMA(1,1,2) fonctionne relativement bien.
- RMSE (erreur quadratique moyenne) = 0,000206. Cela indique que, en moyenne, les prévisions du modèle s'écartent de 0.0206 unités par rapport aux valeurs réelles.

3.1.3 Le processus ARIMA-EGARCH :

Le modèle EGARCH (Generalized Autoregressive Conditional Heteroskedasticity) est conçu pour capturer cette dynamique d'utilisation conditionnelle. Contrairement à ARIMA, qui se concentre sur la moyenne de la série, EGARCH modélise la variance conditionnelle.

En prenant en compte cette condition, on peut observer une amélioration des prévisions de disponibilité, essentielles pour la gestion des risques financiers (notre cas), qui aident à fournir des intervalles de prévision plus réalistes en tenant compte des fluctuations de probabilité.

Et avant de procéder à ce modèle, il faut tout d'abord appliquer le test ARCH, pour détecter la présence d'hétéroscédasticité.

Test ARCH : $p\text{-value} > 5\%$

- Hypothèse nulle (H_0) : Il n'y a pas d'effet ARCH (pas de dépendance dans la variance conditionnelle).
- Hypothèse alternative (H_1) : Il y a un effet ARCH significatif (la variance conditionnelle est autocorrélée).

```
> ArchTest(residualsARIMA1)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residualsARIMA1
Chi-squared = 63.118, df = 12, p-value = 6.063e-09
```

Figure 19 : Test ARCH du modèle ARIMA(1,1,2)

Les résultats du test ARCH LM indiquent que l'hypothèse nulle (« absence d'effets ARCH ») est rejetée pour les deux modèles, puisque les p -values ($6.063e-09$ pour ARIMA(1,1,2)) sont extrêmement faibles. Cela signifie que la volatilité n'est pas constante mais évolue avec le temps.

Pour mieux capturer cette dynamique de préférence, il serait pertinent d'envisager l'utilisation de modèle de type GARCH, qui sont spécialement conçus pour modéliser l'hétéroscédasticité conditionnelle.

3.1.3.1 Le modèle ARIMA-EGARCH :

Pour combiner les forces des deux approches, nous avons intégré un modèle ARIMA pour capturer la composante moyenne de la série, suivi d'un modèle EGARCH pour modéliser la variance conditionnelle.

Le modèle va être ARIMA(p,d,q)-EGARCH(p,q), en déterminant p et q de EGARCH(p,q) par les deux fonctions ACF et PACF appliqué sur les résidus de la série, et pour (p,d,q) du modèle ARIMA vont être les mêmes qui sont utilisés dans la partie précédente.




Figure 20 : ACF sur les résidus de la dérivée de la volatilité sur la période 1
A partir de cette figure, on conclut que q égale à 1.




Figure 21 : PACF sur les résidus de la dérivée de la volatilité sur la période 1
A partir de cette figure, on conclut que p égale à 1.

Donc le modèle à utiliser : ARIMA(1,1,2)-EGARCH(1,1), qui s'écrit comme suit :

$$Volatility' = a_1 * Volatility'_{-1} + b_1 * \varepsilon_{-1} + b_2 * \varepsilon_{-2} + \varepsilon$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma_t^2)$

et $\ln(\sigma_t^2) = \omega + \beta_1 \cdot \ln(\sigma_{t-1}^2) + \alpha_1 \cdot |\varepsilon_{t-1} / \sigma_{t-1}| + \gamma_1 \cdot (\varepsilon_{t-1} / \sigma_{t-1})$

Coefficients ARIMA(1,1,2)-EGARCH(1,1) :

	Estimate	Std. Error	t value	Pr(> t)
mu	0.089487	0.023113	3.8716e+00	0.000108
ar1	0.182081	0.083590	2.1783e+00	0.029387
ma1	-0.124275	0.083798	-1.4830e+00	0.138064
ma2	0.006619	0.008886	7.4488e-01	0.456346
omega	0.015578	0.003053	5.1031e+00	0.000000
alpha1	0.155703	0.010576	1.4723e+01	0.000000
beta1	0.992894	0.000003	2.9061e+05	0.000000
gamma1	0.029528	0.003598	8.2062e+00	0.000000

Figure 22 : Coefficient du modèle ARIMA(1,1,2)-EGARCH(1,1)

- Omega = 0.01558, $p < 0.001$: Ce paramètre de base est significatif et représente le niveau constant de la volatilité dans le logarithme de la variance.
- Alpha1 = 0.15570, $p < 0.001$: Ce coefficient mesure la réaction de la volatilité aux chocs passés (l'impact absolu des innovations). Sa valeur positive et significative montre que des chocs plus importants augmentent la volatilité.
- Beta1 = 0.99289, $p < 0.001$: La valeur de beta1, très proche de 1, indique une influence importante sur la volatilité. Autrement dit, une fois que la volatilité augmente en raison d'un choc, elle reste élevée pendant une longue période.
- Gamma1 = 0.02953, $p < 0.001$: Ce paramètre capture l'asymétrie dans la réponse de la volatilité aux chocs. Une valeur positive suggère que les chocs négatifs (par exemple, une baisse brutale des prix) augmentent la volatilité de manière légèrement plus marquée que les chocs positifs de même ampleur.

3.1.3.2 Validation du modèle ARIMA(1,1,2)-EGARCH(1,1) :

- Test de Weighted Ljung-Box sur les résidus standardisés :

```

weighted Ljung-Box Test on Standardized Residuals
-----
              statistic  p-value
Lag[1]                2.369 1.238e-01
Lag[2*(p+q)+(p+q)-1][8]  3.684 9.157e-01
Lag[4*(p+q)+(p+q)-1][14] 24.103 6.472e-08
d.o.f=3
H0 : No serial correlation
  
```

Figure 23 : Test de Weighted Ljung-Box sur les résidus standardisés du modèle ARIMA(1,1,2)-EGARCH(1,1)

Pour les lags courts (1 et 8), la p-value est suffisamment élevée pour ne pas rejeter l'hypothèse d'absence d'autocorrélation dans les résidus standardisés. Cependant, à un lag plus élevé (lag 14), la p-value très faible indique la présence de dépendance résiduelle. Cela suggère que, malgré un ajustement correct pour les effets immédiats, des autocorrélations subsistent aux lags et longs.

- Test de ARCH LM :

	Statistic	Shape	Scale	P-value
ARCH Lag[3]	0.817	0.500	2.000	0.3661
ARCH Lag[5]	1.043	1.440	1.667	0.7201
ARCH Lag[7]	2.345	2.315	1.543	0.6445

Figure 24 : Test d'ARCH sur le modèle ARIMA(1,1,2)-EGARCH(1,1)

Ces p-values élevées évoquent qu'il n'existe pas d'effets ARCH supplémentaires non modélisés. Autrement dit, le modèle EGARCH(1,1) capture bien la structure conditionnelle de la variance au niveau des effets ARCH.

3.1.3.3 Estimer par le modèle ARIMA(1,1,2)-EGARCH(1,1) :

- MSE (erreur quadratique moyenne) = 0,000427, cette valeur indique que la moyenne des carrés des erreurs est assez petite, ce qui signifie que le modèle ARIMA(1,1,2)-EGARCH(1,1) fonctionne relativement bien.
- RMSE (erreur quadratique moyenne) = 0,000206, cette valeur de RMSE obtenue indique que, en moyenne, les prévisions du modèle s'écartent de 0.00206 unités par rapport aux valeurs réelles.

3.2 Modélisation de la volatilité sur la deuxième période (1991-2024) :

3.2.1 Le processus ARMA(p,q) :

3.2.1.1 Détermination du p et q :

Le choix de l'ordre d'un modèle mixte ARMA(p,q) repose sur l'analyse des deux fonctions suivantes : ACF (q) et PACF (p) .

- Détermination de l'ordre p de AR par la fonction PACF, on obtient le résultat suivant :




Figure 25 : PACF de la série de la volatilité sur la période 2

La fonction PACF s'annule à partir du Lag 1, donc p égale 1 (AR(1)).

- Détermination de l'ordre q se fait à partir du graphe de la fonction ACF, on obtient le résultat suivant :

ACF de la Volatilité 1991-2024




Figure 26 : ACF de la série de la volatilité sur la période 2

La fonction ACF (fonction d'autocorrélation) décroît lentement, cela suggère que la série temporelle peut avoir une dépendance à long terme, ce qui peut être un signe que la série n'est pas stationnaire. Dans ce cas, il est en effet plus approprié d'utiliser un modèle ARIMA (AutoRegressive Integrated Moving Average), qui intègre une composante de différenciation pour rendre la série stationnaire.

3.2.2 Le processus ARIMA(p,d,q) :

3.2.2.1 Le modèle à utiliser :

Le processus ARIMA(p,d,q) est un processus ARMA(p,q) de moyenne nulle intégré d fois. Après la première dérivation, le graphe de la volatilité devient :

dérivé volatilité (Janvier 1991 - Septembre 2024)




Figure 27 : Graphes du dérivé de la volatilité sur la période 2

A partir de ce graphe on dit que le dérivé de la série de la volatilité est stationnaire (d=1). On trace les deux fonction ACF et PACF pour déterminer p et q :

PACF de la Volatilité 1991-2024




Figure 28 : PACF de la dérivée de la volatilité sur la période 2

A partir de ce graphe, on conclut que $p=0$.

ACF de la Volatilité 1990-2024




Figure 29 : ACF du dérivé de la volatilité sur la période 2

A partir de ce graphe, on conclut que $q=1$.

Donc pour estimer la volatilité, le modèle à utiliser est : ARIMA(0,1,2), qui s'écrit comme suit :

$$Volatility' = b_1 * \varepsilon_{-1} + \varepsilon$$

Volatility' est le dérivé de Volatility.

3.2.2.2 Prédiction par ARIMA(0,1,1) :

Coefficients ARIMA(0,1,1) :

```
Call:
arima(x = train2, order = c(0, 1, 1))

Coefficients:
      ma1
    -1.0000
s.e.    0.0092
```

Figure 30 : Coefficient du modèle ARIMA(0,1,1) sur la période 2

- MA(1) = -1 (avec une erreur standard de 0.0092)

Le coefficient MA(1) est négatif (-1), indiquant que la volatilité actuelle est fortement influencée par les chocs passés mais ne dépend pas directement de ses propres valeurs précédentes. Ce coefficient (MA1 = -1.00) signifie aussi qu'un choc haussier de la

volatilité à un instant donné est quasiment entièrement compensé par un choc baissier à la période suivante.

3.2.2.3 Validation du modèle :

La fonction `checkresiduals()` du package `forecasttest` utilisée pour analyser les résidus d'un modèle de série temporelle, comme pour notre modèle $ARIMA(0,1,1)$. Les résidus représentent la différence entre les valeurs enregistrées et les valeurs prédites.




Figure 31 : Présentation des résidus du modèle $ARIMA(0,1,1)$

Autocorrélation des résidus (ACF) : L'analyse de l'autocorrélation des résidus, représentée par la fonction d'autocorrélation (ACF), montre que certaines valeurs d'ACF sortent de la plage proche de zéro (entre -0.05 et 0.05). Cela suggère qu'il y a une corrélation significative dans les résidus du modèle.

Normalité des résidus : Le test de la normalité des résidus révèle que ceux-ci suivent une distribution normale, comme l'indique le test de normalité et la visualisation des résidus. Cela confirme que les erreurs du modèle sont distribuées normalement, ce qui est une hypothèse sous-jacente importante pour la validation du modèle $ARIMA(0,1,1)$ sur la deuxième période.

Test de Ljung-Box des résidus : Le test de Ljung-Box a été effectué pour vérifier l'indépendance des résidus du modèle $ARIMA(0,1,1)$. L'hypothèse nulle du test est que les résidus sont indépendants (absence d'autocorrélation), et l'hypothèse alternative est que les résidus présentent une autocorrélation significative.

```
> checkresiduals(modelARIMA2)

Ljung-Box test

data: Residuals from ARIMA(0,1,1)
Q* = 26.007, df = 9, p-value = 0.002038

Model df: 1. Total lags used: 10
```

Figure 32 : Test de Ljung-Box des résidus du modèle ARIMA(0,1,1)

Résultats du test :

- $Q = 26,007$
- $df = 9$ (degrés de liberté)
- $p\text{-valeur} = 0,002038$

La valeur p du test de Ljung-Box est de 0,002038, ce qui est inférieur au seuil de significativité standard de 0,05. Cela signifie que nous rejetons l'hypothèse nulle selon laquelle les résidus sont indépendants. Autrement dit, les résultats du test suggèrent qu'il y a une autocorrélation significatif dans les résidus du modèle ARIMA(0,1,1). Cela baisse la fiabilité du modèle ARIMA(0,1,1) sur la deuxième période.

3.2.2.4 Estimer par le modèle ARIMA(0,1,1) :

MSE (erreur quadratique moyenne) = 0,000263. Cela indique que la moyenne des carrés des erreurs est assez petite, ce qui signifie que le modèle ARIMA(0,1,1) fonctionne relativement bien.

RMSE (erreur quadratique moyenne) = 0,000162. Cela indique que, en moyenne, les prévisions du modèle s'écartent de 0.000162 unités par rapport aux valeurs réelles.

3.2.3 Le processus ARIMA-EGARCH :

Le modèle EGARCH (Generalized Autoregressive Conditional Heteroskedasticity) est conçu pour capturer cette dynamique d'utilisation conditionnelle. Contrairement à ARIMA, qui se concentre sur la moyenne de la série, EGARCH modélise la variance conditionnelle.

En prenant en compte cette condition, on peut observer une amélioration des prévisions de disponibilité, essentielles pour la gestion des risques financiers (notre cas), qui aident à fournir des intervalles de prévision plus réalistes en tenant compte des fluctuations de probabilité.

Et avant de procéder à ce modèle, il faut tout d'abord appliquer le test ARCH, pour détecter la présence d'hétéroscédasticité.

Test ARCH : $p\text{-value} > 5\%$

- Hypothèse nulle (H_0) : Il n'y a pas d'effet ARCH (pas de dépendance dans la variance conditionnelle).
- Hypothèse alternative (H_1) : Il y a un effet ARCH significatif (la variance conditionnelle est autocorrélée).


```
> ArchTest(residualsARIMA2)

ARCH LM-test; Null hypothesis: no ARCH effects

data: residualsARIMA2
Chi-squared = 59.645, df = 12, p-value = 2.619e-08
```

Figure 33 : Test ARCH sur le modèle ARIMA(0,1,1)

Les résultats du test ARCH LM indiquent que l'hypothèse nulle (« absence d'effets ARCH ») est rejetée pour les deux modèles, puisque les p-values ($2.619e-08$ pour ARIMA(0,1,1)) sont extrêmement faibles. Cela signifie que la volatilité n'est pas constante mais évolue avec le temps.

Pour mieux capturer cette dynamique de préférence, il serait pertinent d'envisager l'utilisation de modèle de type GARCH, qui sont spécialement conçus pour modéliser l'hétéroscédasticité conditionnelle.

3.2.3.1 Le modèle ARIMA-EGARCH :

Pour combiner les forces des deux approches, nous avons intégré un modèle ARIMA pour capturer la composante moyenne de la série, suivi d'un modèle EGARCH pour modéliser la variance conditionnelle.

Le modèle va être ARIMA(p,d,q)-EGARCH(p,q), en déterminant p et q de EGARCH(p,q) par les deux fonctions ACF et PACF appliqué sur les résidus de la série, et pour (p,d,q) du modèle ARIMA vont être les mêmes qui sont utilisés dans la partie précédente.

ACF residual² 1991-2024




Figure 34 : ACF sur les résidus de la dérivée de la volatilité de la période 2
A partir de cette figure, on conclut que q égale à 1.

PACF residual² 1991-2024




Figure 35 : PACF sur les résidus de la dérivée de la volatilité de la période 2

A partir de cette figure, on conclut que p égale à 0.

Donc le modèle à utiliser : ARIMA(0,1,1)-EGARCH(0,1), qui s'écrit comme suit :

$$Volatility' = b_1 * \varepsilon_{-1} + \varepsilon$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma_t^2)$

et $\ln(\sigma_t^2) = \omega + \beta_1 \cdot \ln(\sigma_{t-1}^2)$

Coefficients ARIMA(0,1,1)-EGARCH(0,1) :

Optimal Parameters				
	Estimate	Std. Error	t value	Pr(> t)
mu	-0.008840	0.091679	-0.096426	0.923183
ma1	0.027585	0.049485	0.557429	0.577235
omega	0.126817	0.496517	0.255414	0.798403
beta1	0.891623	0.429346	2.076698	0.037829

Figure 36 : Coefficient du modèle ARIMA(0,1,1)-EGARCH(0,1)

- $\omega = 0.12682$: Le paramètre constant de la variance n'est pas significatif ($p = 0.798$). Cela peut indiquer que la composante de base de la préférence n'apporte pas d'information de manière considérable.
- $\beta_1 = 0.89162$: Ce coefficient est significatif ($p = 0.0378$) et indique une forte persistance de la volatilité. Autrement dit, une augmentation de la volatilité conditionnelle tend à se maintenir sur la période suivante.

3.2.3.2 Validation de modèle ARIMA(0,1,1)-EGARCH(0,1) :

- Test de Weighted Ljung-Box sur les résidus standardisés :

Weighted Ljung-Box Test on Standardized Residuals		
	statistic	p-value
Lag[1]	0.0000148	0.9969
Lag[2*(p+q)+(p+q)-1][2]	0.0018869	1.0000
Lag[4*(p+q)+(p+q)-1][5]	0.7464172	0.9774
d.o.f=1		
H0 : No serial correlation		

Figure 37 : Test de Weighted Ljung-Box sur les résidus standardisés du modèle ARIMA(0,1,1)-EGARCH(0,1)

Les très fortes p-values indiquent que les résidus standardisés ne présentent pas d'autocorrélation significative. Cela suggère que le modèle capture bien la dynamique de la moyenne au niveau des résidus.

- Teste de ARCH LM :

Weighted ARCH LM Tests				
	Statistic	Shape	scale	P-value
ARCH Lag[2]	0.1200	0.500	2.000	0.7290
ARCH Lag[4]	0.1883	1.397	1.611	0.9624
ARCH Lag[6]	0.2444	2.222	1.500	0.9936

Figure 38 : Test d'ARCH sur le modèle ARIMA(0,1,1)-EGARCH(0,1)

Pour les décalages 2, 4 et 6, les p-values (0.729, 0.9624 et 0.9936 respectivement) sont très élevées. Ces tests ne montrent aucune preuve d'effets ARCH supplémentaires. Le modèle EGARCH(0,1) semble donc suffisant pour modéliser l'hétéroscédasticité conditionnelle de la série.

3.2.3.3 Estimer par le modèles ARIMA(0,1,1)-EGARCH(0,1) :

MSE (erreur quadratique moyenne) = 0,000259, cette valeur indique que la moyenne des carrés des erreurs est assez petite, ce qui signifie que le modèle ARIMA(0,1,1)-EGARCH(0,1) fonctionne relativement bien.

RMSE (erreur quadratique moyenne) = 0,000161, cette valeur de RMSE obtenue indique que, en moyenne, les prévisions du modèle s'écartent de 0.00161 unités par rapport aux valeurs réelles.

3.3 Conclusion :

	Modèles	MSE1	RMSE1	MSE2	RMSE2
1	ARIMA	0.000427199856290281	0.000206688136159355	0.000263756289580159	0.000162405754079145
2	ARIMA-EGARCH	0.000427175051729759	0.000206682135592256	0.000259933052082732	0.000161224393961563

Figure 39 : Récapitulatif des MSE et RMSE des modèles utilisés dans cette partie

L'ARIMA et l'ARIMA-EGARCH ont des performances très similaires sur les deux périodes. En effet, leurs MSE et RMSE sont quasiment identiques (MSE1 $\approx$ 0.000427 et MSE2 $\approx$ 0.000263 pour ARIMA, contre MSE1 $\approx$ 0.000427 et MSE2 $\approx$ 0.000259 pour ARIMA-EGARCH). Cependant, ARIMA-EGARCH présente de très légères améliorations, notamment en Période 2, où son MSE est légèrement plus faible que celui de l'ARIMA classique. Cela suggère que la prise en compte de l'hétéroscédasticité (variabilité de la variance) par le modèle EGARCH apporte une petite, mais cette différence reste minime. En conclusion, ARIMA-EGARCH est légèrement meilleur qu'ARIMA.

Ces modèles ARIMA-EGARCH ont montré certaines limites :

- Une instabilité des paramètres,
- Une autocorrélation résiduelle
- Une mauvaise adaptation aux variations du marché.

Ces faiblesses diminuent leur précision prédictive. Pour mieux capturer la complexité des données financières, les modèles de machine learning offrent une alternative plus flexible et performante, capable d'adapter les prévisions aux dynamiques du marché.

Chapitre 4 : Modélisation de la volatilité par machine learning

4.1 Intelligence Artificielle :

L'intelligence artificielle (IA) désigne l'ensemble des techniques et algorithmes informatiques conçus pour accomplir des tâches habituellement attribuées à l'intelligence humaine, telles que :

- L'apprentissage
- La résolution de problèmes
- La prise de décisions, entre autres.




Figure 40 : Les constituants du IA

L'intelligence artificiel regroupe trois catégories :

- Robotique : La conception et la réalisation de machines capables d'exécuter des tâches de manière autonome, sans intervention humaine.
- NLP (traitement du langage naturel) : L'objectif du NLP est de permettre aux ordinateurs de comprendre, interpréter et traiter le langage humain, qu'il soit écrit ou oral.
- Machine Learning : Le ML est un domaine d'étude qui vise à permettre aux machines d'apprendre par elles-mêmes sans être explicitement programmées.

4.1.1 Machine Learning :

Le machine learning est une méthode de création de modèles capables d'apprendre à partir de données observées. Ces modèles permettent ensuite de prédire et d'analyser de nouvelles données.

Prenant notre cas, prédire la volatilité peut être exprimée comme une fonction de plusieurs facteurs déterminants. Cette modélisation vise à analyser l'influence de ces variables sur les fluctuations des marchés financiers et à mieux comprendre les dynamiques sous-jacentes.

Les prédictions se font par l'une des méthodes ci-dessous :




Figure 50 : Les différentes méthodes du Machine Learning

Pour notre cas, on va utiliser l'apprentissage supervisé, qui contient deux méthodes différentes :

- Classification : Un modèle est qualifié de classification lorsque la variable cible à expliquer est discrète, c'est-à-dire catégorielle.
- Régression : Un modèle est qualifié de régression lorsque la variable cible à expliquer est continue, c'est-à-dire quantitative.

Selon notre cas, la volatilité est une variable continue, donc le modèle le plus approprié est la régression.

4.2 Modélisation de la volatilité sur la première période (1881-1990) :

4.2.1 Modèle Ridge :

4.2.1.1 Définition :

L'objectif de la régression Ridge est de trouver le vecteur β solution du problème suivant :

$$\left\{ \begin{array}{l} \text{Min}_{\beta} ||Y - X\beta||_2^2 \\ \text{sc} : ||\beta||_2^2 \leq C^2 \end{array} \right.$$

Avec :

- Y : Le vecteur volatilité
- X : La matrice des autres variables




Figure 51 : Représentation de l'optimisation du modèle Ridge

$||\beta||_2^2 = \sum \beta_j^2$ est le carré de la norme euclidienne (norme 2).

Ce problème présenté peut être écrit sous la forme suivante :

$$\text{Min}_{\beta} ||Y - X\beta||_2^2 + \lambda * ||\beta||_2^2$$

Avec $\lambda \geq 0$ est un coefficient de régularisation.

Plus λ est grand plus on donne de l'importance à $\lambda * ||\beta||_2^2$ par rapport à $||Y - X\beta||_2^2$, donc minimiser le problème revient à minimiser $||\beta||_2^2$ c'est-à-dire les β_j (les autres variables)

4.2.1.2 Préparation des données :

Pour commencer avec les modèles de machine learning, nous devrions préparer les données en suivant les étapes suivantes :

- Construction des bases de données d'entraînement (train) et de test (test) pour les deux périodes.
- Suppression de la colonne « volatility » dans les bases train et test pour éviter le sur-apprentissage.
- Conservation des valeurs de préférence dans des vecteurs séparés pour une vérification après l'entraînement du modèle.

4.2.1.3 Construction du modèle :

Mathématiquement le modèle se présente comme suit :

$$\text{min} : (Y - (\beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \beta_3 \cdot X_3))^2 + \lambda \cdot (\beta_1^2 + \beta_2^2 + \beta_3^2)$$

avec :

- X_1 : Rendement
- X_2 : Taux d'intérêt
- X_3 : Taux de croissance des dividendes

Pour utiliser ce modèle il faut Installer et charger la bibliothèque « glmnet », et spécifier dans le modèle les caractéristiques suivantes :

- `type.measure="mse"` : Spécifie que l'erreur quadratique moyenne (Mean Squared Error, MSE) sera utilisée comme métrique pour évaluer les modèles pendant la validation croisée.

- $\alpha=0$: Définit le type de régularisation
- `family="gaussian"` : Indique que la distribution cible est gaussienne (ou normale), ce qui correspond à une régression linéaire standard.
- `nlambda=200` : Le nombre de valeurs de λ (paramètre de régularisation) à tester. Le modèle essaiera 200 valeurs différentes de λ pour déterminer celle qui minimise le MSE.

Cela nous donne comme résultat pour des différentes λ :




Figure 52 : graphe des différentes Lambda pour le modèle Ridge sur période 1 (Mean-Squared Error est multipliée par 100^2)

Le meilleur modèle pour prédire est celui qui a Lambda la plus petite, donc on fait appel à la fonction `Min` pour déterminer Lambda la plus petite : $\text{Lambda} = 0.01662116$

4.2.1.4 Modèle obtenu :

```
> coef(modelRidge11)
4 x 1 sparse Matrix of class "dgCMatrix"
s0
(Intercept)      0.029211575
DividendGrowthRate 0.006521432
InterestRate     -0.050691707
Yield            -0.126249941
```

Figure 53 : Coefficient du modèle Ridge sur la période 1

- Constante (Intercept = 0.0292) : Lorsque toutes les variables explicatives sont nulles, la volatilité moyenne estimée est de 0.0292.
- DividendGrowthRate (0.0065) : Une augmentation d'un point du taux de croissance des dividendes est associée à une légère augmentation de la volatilité de 0.0065 unités, toutes choses égales par ailleurs.
- InterestRate (-0.0507) : Une hausse d'un point du taux d'intérêt est liée à une diminution de la volatilité estimée de 0.0507 unités. Cela suggère un effet stabilisateur des taux sur le marché durant cette période.
- Yield (-0.1262) : Le rendement a l'impact négatif le plus marqué. Une hausse du rendement est associée à une forte baisse de la volatilité, indiquant que des perspectives de gain plus élevées peuvent réduire l'incertitude sur le marché.

Pendant la période 1881–1990, la volatilité semble faiblement influencée par la croissance des dividendes, mais plus fortement régulée par les taux d'intérêt et surtout le rendement, qui apparaît comme le facteur le plus stabilisant selon ce modèle Ridge.

4.2.1.5 Prédiction et validation du modèle :

Pour valider ce modèle, on l'a utilisé à prédire certaines valeurs, et on a calculé la différence entre les valeurs réelles et les valeurs prédites, et on a obtenu comme résultats :

MSE = 0,0002045958 : La faible erreur quadratique moyenne indique que la distance au carré entre les prédictions et les valeurs réelles est presque négligeable.

RMSE = 0,000143037 : La racine carrée du MSE (RMSE) indique une erreur moyenne absolue très faible, suggérant que le modèle prédit avec précision les valeurs de la cible (volatilité).

La régression Ridge, bien qu'efficace pour limiter la surapprentissage en particulier l'amplitude des coefficients, conserve toutes les variables dans le modèle, même celles ayant une contribution négligeable à la prédiction. Ce problème a été observé dans notre modèle.

Pour résoudre cela, nous avons opté pour la régression Lasso. Contrairement à Ridge, Lasso minimise les coefficients des variables non pertinentes, simplifiant ainsi le modèle et facilitant l'identification des variables réellement significatives.

4.2.2 Modèle Lasso :

4.2.2.1 Définition :

L'objectif de la régression Lasso est de trouver le vecteur β solution du problème suivant :

$$\left\{ \begin{array}{l} \text{Min}_{\beta} ||Y - X\beta||_2^2 \\ \text{sc} : ||\beta||_1 \leq C^2 \end{array} \right.$$

Avec :

- Y : Le vecteur volatilité
- X : La matrice des autres variables




Figure 54 : Présentation de l'optimisation du modèle Lasso

$$||\beta||_1 = \sum |\beta_j| \text{ est la norme 1.}$$

Ce problème présenté peut être écrit sous la forme suivante :

$$\text{Min}_{\beta} ||Y - X\beta||_2^2 + \lambda * ||\beta||_1$$

Avec $\lambda \geq 0$ est un coefficient de régularisation.

Avec cette formulation, il y a des chances d'avoir des $\beta_j = 0$

4.2.2.2 Construction du modèle :

Notre modèle s'écrit comme suit :

$$\min : (Y - (\beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \beta_3 \cdot X_3))^2 + \lambda \cdot (|\beta_1| + |\beta_2| + |\beta_3|)$$

avec :

- X_1 : Rendement
- X_2 : Taux d'intérêt
- X_3 : Croissance des dividendes

On suit la même démarche que celle du modèle Ridge, mais au niveau du modèle, on fait un petit changement sur alpha, elle devient égale 1 à la place de 0.

Ce qui nous donne le résultat suivant :




Figure 55 : graphe des différentes Lambda pour le modèle Lasso sur période 1 (MSE est multiplié par 10000)

Le modèle le plus efficace, et celui qui prend toujours lambda la plus petite : Lambda = 0.0006740645

4.2.2.3 Modèle obtenu :

On obtient comme résultat le suivant :

```
> coef(modelLasso11)
4 x 1 sparse Matrix of class "dgCMatrix"
              s0
(Intercept)    0.029211575
DividendGrowthRate 0.005959105
InterestRate   -0.050525844
Yield          -0.126613975
```

Figure 56 : Coefficient du modèle Lasso sur la période 1

- Le rendement (Yield) a l'effet le plus fort et négatif sur la volatilité.
- Le taux d'intérêt a également un effet modérément négatif.
- Le taux de croissance des dividendes a un effet positif mais très faible.

Le modèle a conservé toutes les variables, donc pas de mise à zéro malgré la régularisation : cela signifie qu'elles ont toutes une contribution explicative dans la période.

4.2.2.4 Prédiction et validation du modèle :

Pour valider ce modèle, on l'a utilisé à prédire certaines valeurs, et on a calculé la différence entre les valeurs réelles et les valeurs prédites, et on a obtenu comme résultats :

MSE = 0.0002045949 : La faible erreur quadratique moyenne indique que la distance au carré entre les prédictions et les valeurs réelles est presque négligeable.

RMSE = 0.0001430367 : La racine carrée du MSE (RMSE) indique une erreur moyenne absolue très faible, suggérant que le modèle prédit avec précision les valeurs de la cible (volatilité).

4.2.3 Modèle ElasticNet :

4.2.3.1 Définition :

La méthode Elastic Net combine les régularisations de la norme 1 et de la norme 2. Le problème s'exprime comme suit :

$$\left\{ \begin{array}{l} \min_{\beta} ||Y - X\beta||_2^2 + \lambda * [\alpha * ||\beta||_1 + (1 - \alpha) * ||\beta||_2^2] \\ \lambda \geq 0 \\ \alpha \in [0,1] \end{array} \right.$$

La figure ci-dessous illustre la relation entre les trois méthodes (Lasso, Ridge et ElasticNet) :




Figure 57 : Représentation des optimisations des modèles (Lasso / Ridge / ElasticNet)
On voit bien que le troisième graphe prend la solution qui se trouve entre les deux points déterminés par les méthodes Lasso et Ridge, donc c'est une optimisation des deux méthodes.

4.2.3.2 Construction du modèle :

La construction du modèle ElasticNet consiste à déterminer la valeur de Lambda et Alpha :

- Réalisation d'une boucle "For" faisant varier Alpha de 0 à 1 avec un pas de 0,001.
- Association d'un modèle à chaque valeur de Alpha dans l'intervalle [0,1].
- Calcul des valeurs prédites par le modèle correspondant en utilisant la plus petite valeur de Lambda.
- Évaluation de la performance en calculant l'erreur quadratique moyenne (MSE) et en l'enregistrant dans un vecteur.
- Sélection du meilleur modèle en identifiant celui avec la plus petite MSE, permettant ainsi de déterminer les valeurs optimales d'Alpha et Lambda.

Le meilleur modèle est celui avec MSE la plus petite :

1881-1990




Figure 58 : Graphes MSE en fonction de Alpha du modèle ElasticNet sur période 1
Cette figure illustre les valeurs d'Alphas utilisées avec les MSE calculés, on doit choisir Alphas optimale : Alpha=0,078

La figure ci-dessous illustre les valeurs de Lambda pour ce modèle :




Figure 58 : graphe des différentes Lambda pour le modèle ElasticNet sur période 1 pour Alpha choisi

La meilleure valeur de Lambda est la plus petite, $\text{Lambda}=0.006250335$

4.2.3.3 Modèle obtenu :

On obtient comme résultat le suivant :

```
> coef(ElasticNet11)
4 x 1 sparse Matrix of class "dgCMatrix"

s0
(Intercept)      0.029211575
DividendGrowthRate 0.006100184
InterestRate     -0.050529788
Yield            -0.126425891
```

Figure 59 : Coefficient du modèle ElasticNet sur période 1

- Comme pour le Lasso et le Ridge, Yield est le facteur le plus influent, avec un effet négatif fort sur la volatilité.
- InterestRate a un effet modéré, également négatif.
- DividendGrowthRate a un effet positif, mais très faible.
- L'Elastic Net combine les propriétés du Lasso et du Ridge : ici, il n'a mis aucun coefficient à zéro, ce qui suggère que toutes les variables contribuent à l'explication.

4.2.3.4 Prédiction et validation du modèle :

Pour valider ce modèle, on l'a utilisé à prédire certaines valeurs, et on a calculé la différence entre les valeurs réelles et les valeurs prédites, et on a obtenu comme résultats :

MSE = 0,0002045917 : La faible erreur quadratique moyenne indique que la distance au carré entre les prédictions et les valeurs réelles est presque négligeable.

RMSE = 0,0001430355 : La racine carrée du MSE (RMSE) indique une erreur moyenne absolue très faible, suggérant que le modèle prédit avec précision les valeurs de la cible (volatilité).

4.2.4 Réseaux de neurones :

4.2.4.1 Définition :

Un réseau de neurones est un modèle informatique inspiré du fonctionnement du cerveau humain. Il est composé de plusieurs couches de nœuds interconnectés qui traitent l'information de manière progressive.

Le réseau fonctionne en analysant les données à différents niveaux d'abstraction. Les premières couches identifient des éléments simples, tandis que les couches plus profondes détectent des caractéristiques plus complexes. Cette capacité d'apprentissage repose sur l'ajustement automatique du poids des connexions entre les nœuds, en suivant une règle d'apprentissage spécifique. Plus le réseau est entraîné sur un grand nombre d'exemples, plus il devient performant dans la tâche pour laquelle il est conçu.

L'image suivante illustre cette architecture en montrant les neurones d'entrée, les couches cachées (où se produit l'apprentissage), et les neurones de sortie qui fournissent la prédiction finale :




Figure 60 : Architecture d'un réseau de neurones

- Les neurones d'entrée : ils représentent les variables d'entrée du modèle, pour notre cas vont être les variables explicatives.
- Les neurones de sortie : ils fournissent le résultat final du modèle, pour notre cas un seul neurone de sortie va être la volatilité.
- Les couches cachées : ce sont des couches intermédiaires situées entre les neurones d'entrée et les neurones de sortie. Elles permettent au réseau d'apprendre des représentations complexes des données en appliquant des transformations successives. Chaque couche cachée est composée de neurones interconnectés, qui

reçoivent des informations des couches précédentes et les transmettent aux couches suivantes après application d'une fonction d'activation.

4.2.4.2 *Modèle réseau de neurones à une seule couche cachée :*

Ce type de modèle nécessite une normalisation des données avant son entraînement. La normalisation permet de ramener les valeurs des variables dans une même échelle, ce qui améliore l'efficacité du modèle en particulier que certaines caractéristiques ne dominent les autres en raison de leur échelle. Sous R, on peut construire une fonction pour normaliser les données en les ramenant dans l'intervalle [0,1] en fonction de leurs valeurs minimales et maximales.

Pour déterminer le nombre optimal de neurones dans la couche cachée, on teste plusieurs configurations en faisant varier ce nombre de 1 à 12. Pour chaque configuration, on entraîne le modèle et on réalise sa performance en calculant l'erreur quadratique moyenne (MSE) entre les valeurs réelles et les valeurs prédites. Enfin, on sélectionne le nombre de neurones qui correspondent à la MSE la plus faible, garantissant ainsi le meilleur compromis entre complexité et performance du modèle.

Cette figure illustre la variation de la MSE en fonction du nombre de neurones dans la couche cachée (MSE est multipliée par 10000) :




Figure 61 : Graphes MSE (multiplié par 10000) en fonction de nombre de neurones dans la couche cachée pour période 1

	NbrNeurones	mseNN1
3	3	2.055730
1	1	2.102714
2	2	2.220394
12	12	4.751799
11	11	5.439324
8	8	5.670773
6	6	5.748930
10	10	5.825711
4	4	7.221447
7	7	7.823762
5	5	8.320726
9	9	17.184281

Figure 62 : Tableau MSE (multipliée par 10000) pour chaque nombre de neurones cachés pour période 1

La MSE la plus faible correspond à trois neurones dans la couche cachée, cela signifie que le modèle atteint sa meilleure performance avec cette configuration.

Donc Les réseaux ayant trois neurones dans la couche cachée offrent les meilleurs résultats. Ainsi, le modèle retenu pour notre réseau de neurones comprend 3 neurones d'entrée, 3 neurones cachés et 1 neurone de sortie, comme présenté dans la figure suivante :




Figure 63 : Réseau de neurones d'une seule couche cachée pour la période 1

- Les poids indiqués sur les flèches représentent la force et le sens de l'influence entre les neurones.

- Exemple :
 - Le Yield envoie un signal très négatif à certains neurones cachés, comme le poids -4.94629, ce qui signifie que le réseau perçoit cette variable comme très influente (de façon négative) sur la sortie finale.
 - Ensuite, chaque neurone caché influence Volatility selon un poids, comme par exemple -0.984471, ce qui amplifie ou atténue l'effet initial.
- Yield a un impact majeur (valeurs de poids élevées), ce qui est cohérent avec les modèles Ridge, Lasso, etc.
- Les variables InterestRate et DividendGrowthRate ont un effet plus modéré.
- Le réseau permet de capturer des relations non linéaires complexes entre les variables d'entrée et la volatilité, en combinant les poids dans la couche cachée.

4.2.4.3 Réseau de neurones à deux couches cachées :

Pour déterminer le nombre optimal de neurones dans les deux couches cachées, on teste plusieurs configurations en faisant varier le nombre de neurones de 1 à 6 dans chaque couche (36 combinaisons obtenus). Pour chaque configuration, on entraîne le modèle et on évalue sa performance en calculant l'erreur quadratique moyenne (MSE) entre les valeurs réelles et les valeurs prédites. Enfin, on sélectionne la configuration avec le nombre de neurones qui donne au MSE le plus faible, assurant ainsi un bon équilibre entre la complexité du modèle et sa performance.

Cette figure illustre la variation de la MSE en fonction du nombre de neurones dans les deux couches cachées pour les deux périodes étudiées (MSE est multipliée par 10000) :




Figure 64 : Graphes MSE (multiplié par 10000) en fonction de nombre de neurones dans les deux couches cachées pour période 1

	NbrNeurones1	NbrNeurones2	mseNN1	CombinedLabels
7	2	1	2.000873	(2, 1)
19	4	1	2.002631	(4, 1)
14	3	2	2.006774	(3, 2)
22	4	4	2.007181	(4, 4)
29	5	5	2.013807	(5, 5)
27	5	3	2.013978	(5, 3)
6	1	6	2.014017	(1, 6)
8	2	2	2.016710	(2, 2)
3	1	3	2.037049	(1, 3)
13	3	1	2.048025	(3, 1)
12	2	6	2.055480	(2, 6)
23	4	5	2.064058	(4, 5)
4	1	4	2.072677	(1, 4)

Figure 65 : Tableau MSE (multipliée par 10000) pour chaque nombre de neurones cachés pour période 1

La MSE la plus faible correspond à 2 neurones dans la première couche cachée et un seul neurone dans la deuxième couche cachée, cela signifie que le modèle atteint sa meilleure performance avec cette configuration.

Donc les réseaux ayant 2 neurones dans la première couche cachée et un seul neurone dans la deuxième couche cachée offrent les meilleurs résultats. Ainsi, le modèle retenu pour notre réseau de neurones comprend 3 neurones d'entrée, (2,1) neurones cachés et 1 neurone de sortie, comme présenté dans la figure suivante :




Figure 66 : Réseau de neurones de deux couches cachées pour la période 1

- Chaque variable d'entrée (DividendGrowth, InterestRate, Yield) est connectée aux 2 neurones de la première couche cachée, exemples :
 - Yield → Neurone 1 avec -24.08 : effet très fort et négatif

- InterestRate → Neurone 2 avec +2.48 : effet positif
- DividendGrowth → Neurone 1 avec -2.83
- Les 2 neurones cachés (1^{re} couche) envoient ensuite leur activation vers un seul neurone de la deuxième couche cachée, Exemple :
 - Neurone caché 1 → caché 2 : -0.86208
 - Neurone caché 2 → caché 2 : +0.29844
- Ce dernier neurone caché est connecté à la sortie (Volatility) avec un poids positif (3.45329) : il transmet donc une influence nette positive.

4.3 Modélisation de la volatilité sur la deuxième période (1991-2024) :

4.3.1 Modèle Ridge :

4.3.1.1 Construction du modèle :

Mathématiquement le modèle se présente comme suit :

$$\min : (Y - (\beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \beta_3 \cdot X_3 + \beta_4 \cdot X_4 + \beta_5 \cdot X_5 + \beta_6 \cdot X_6))^2 + \lambda \cdot (\beta_1^2 + \beta_2^2 + \beta_3^2 + \beta_4^2 + \beta_5^2 + \beta_6^2)$$

avec :

- X_1 : Rendement
- X_2 : Taux d'intérêt
- X_3 : Taux de croissance des dividendes
- X_4 : VIX
- X_5 : Confiance des investisseurs
- X_6 : Indice d'émotion

Pour utiliser ce modèle il faut Installer et charger la bibliothèque « glmnet », et spécifier dans le modèle les caractéristiques suivantes :

- `type.measure="mse"` : Spécifie que l'erreur quadratique moyenne (Mean Squared Error, MSE) sera utilisée comme métrique pour évaluer les modèles pendant la validation croisée.
- `alpha=0` : Définit le type de régularisation
- `family="gaussian"` : Indique que la distribution cible est gaussienne (ou normale), ce qui correspond à une régression linéaire standard.
- `nlambdas=200` : Le nombre de valeurs de λ (paramètre de régularisation) à tester. Le modèle essaiera 200 valeurs différentes de λ pour déterminer celle qui minimise le MSE.

Cela nous donne comme résultat pour des différentes λ :




Figure 67 : graphe des différentes Lambda pour le modèle Ridge sur période 2
(Mean-Squared Error est multipliée par 100^2)

Le meilleur modèle pour prédire est celui qui a Lambda la plus petite, donc on fait appel à la fonction Min pour déterminer Lambda la plus petite : $\text{Lambda} = 0.03473535$

4.3.1.2 Modèle obtenu :

```
> coef(modelRidge22)
7 x 1 sparse Matrix of class "dgCMatrix"
              s0
(Intercept)  -0.002173742
DividendGrowthRate -0.074358496
InterestRate   -0.185035771
Yield          -0.139574862
VIX            0.249654369
Emotion        0.071681005
Confidence     -0.241784799
```

Figure 68 : Coefficient du modèle Ridge sur la période 2

- VIX a le plus fort impact positif sur la volatilité : une hausse de l'indice de peur est logiquement liée à une hausse de la volatilité.
- Confidence a un fort effet négatif : quand la confiance augmente, la volatilité diminue nettement.
- InterestRate et Yield ont aussi des effets négatifs significatifs.
- Emotion a un impact positif modéré, indiquant qu'un climat émotionnel plus intense est associé à plus de volatilité.
- DividendGrowthRate diminue légèrement la volatilité.
- Intercept est très proche de zéro, donc la contribution de base (sans les variables) est négligeable.

Contrairement à la période 1881–1990, ce modèle montre que la volatilité est fortement influencée par des facteurs comportementaux et psychologiques :

- Le VIX et le sentiment de confiance ont plus d'effet que les variables macroéconomiques classiques.
- Cela illustre bien un changement dans la nature des marchés, devenus plus sensibles à la perception du risque qu'aux fondamentaux.

4.3.1.3 Prédiction et validation du modèle :

Pour valider ce modèle, on l'a utilisé à prédire certaines valeurs, et on a calculé la différence entre les valeurs réelles et les valeurs prédites, et on a obtenu comme résultats :

- MSE = 0,0004826212 : La faible erreur quadratique moyenne indique que la distance au carré entre les prédictions et les valeurs réelles est presque négligeable.
- RMSE = 0,0002196864 : La racine carrée du MSE (RMSE) indique une erreur moyenne absolue très faible, suggérant que le modèle prédit avec précision les valeurs de la cible (volatilité).

La régression Ridge, bien qu'efficace pour limiter la surapprentissage en particulier l'amplitude des coefficients, conserve toutes les variables dans le modèle, même celles ayant une contribution négligeable à la prédiction. Ce problème a été observé dans notre modèle.

Pour résoudre cela, nous avons opté pour la régression Lasso. Contrairement à Ridge, Lasso minimise les coefficients des variables non pertinentes, simplifiant ainsi le modèle et facilitant l'identification des variables réellement significatives.

4.3.2 Modèle Lasso :

4.3.2.1 Construction du modèle :

Notre modèle s'écrit comme suit :

$$\min : (Y - (\beta_0 + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \beta_3 \cdot X_3 + \beta_4 \cdot X_4 + \beta_5 \cdot X_5 + \beta_6 \cdot X_6))^2 + \lambda \cdot (|\beta_1| + |\beta_2| + |\beta_3| + |\beta_4| + |\beta_5| + |\beta_6|)$$

avec :

- X_1 : Rendement
- X_2 : Taux d'intérêt
- X_3 : Croissance des dividendes
- X_4 : VIX
- X_5 : Confiance des investisseurs
- X_6 : Indice d'émotion

On suit la même démarche que celle du modèle Ridge, mais au niveau du modèle, on fait un petit changement sur alpha, elle devient égale 1 à la place de 0.

Ce qui nous donne le résultat suivant :




Figure 69 : graphe des différentes Lambda pour le modèle Lasso sur période 2
(MSE est multiplié par 10000)

Le modèle le plus efficace, et celui qui prend toujours lambda la plus petite : $\lambda = 0.00245481$

4.3.2.2 Modèle obtenu :

On obtient comme résultat le suivant :

```
> coef(modelLasso22)
7 x 1 sparse Matrix of class "dgCMatrix"
              s0
(Intercept)   -0.002173742
DividendGrowthRate -0.073489674
InterestRate   -0.186256659
Yield          -0.139437709
VIX            0.252395491
Emotion        0.070117293
Confidence     -0.244057198
```

Figure 70 : Coefficient du modèle Lasso sur la période 2

- VIX (indice de peur) a toujours l'effet positif le plus fort : plus le marché anticipe de la peur, plus la volatilité augmente.
- Confidence garde un effet négatif important : les périodes de confiance réduisent la volatilité.
- InterestRate et Yield ont également des effets négatifs notables, traduisant l'influence des conditions économiques.
- Emotion a un impact modéré, mais positif, reflétant le rôle des dynamiques émotionnelles sur les marchés.
- DividendGrowthRate a un faible impact négatif.
- Le terme constant est très proche de zéro.

Le modèle Lasso confirme les résultats du Ridge, en mettant en évidence l'importance du VIX et de la confiance des investisseurs comme principaux facteurs explicatifs de la volatilité.

Le Lasso n'a pas mis de coefficients à zéro ici, ce qui signifie que toutes les variables apportent une contribution significative, même légère.

4.3.2.3 Prédiction et validation du modèle :

Pour valider ce modèle, on l'a utilisé à prédire certaines valeurs, et on a calculé la différence entre les valeurs réelles et les valeurs prédites, et on a obtenu comme résultats :

- $MSE = 0.000482355$: La faible erreur quadratique moyenne indique que la distance au carré entre les prédictions et les valeurs réelles est presque négligeable.
- $RMSE = 0.0002196258$: La racine carrée du MSE (RMSE) indique une erreur moyenne absolue très faible, suggérant que le modèle prédit avec précision les valeurs de la cible (volatilité).

4.3.3 Modèle ElasticNet :

4.3.3.1 Construction des modèles :

La construction du modèle ElasticNet consiste à déterminer la valeur de Lambda et Alpha :

- Réalisation d'une boucle "For" faisant varier Alpha de 0 à 1 avec un pas de 0,001.
- Association d'un modèle à chaque valeur de Alpha dans l'intervalle [0,1].
- Calcul des valeurs prédites par le modèle correspondant en utilisant la plus petite valeur de Lambda.
- Évaluation de la performance en calculant l'erreur quadratique moyenne (MSE) et en l'enregistrant dans un vecteur.
- Sélection du meilleur modèle en identifiant celui avec la plus petite MSE, permettant ainsi de déterminer les valeurs optimales d'Alpha et Lambda.

Le meilleur modèle est celui avec MSE la plus petite :

1990-2024




Figure 71 : Graphes MSE en fonction de Alpha du modèle ElasticNet sur période 2
Cette figure illustre les valeurs d'Alphas utilisées avec les MSE calculés, on doit choisir Alphas optimale : Alpha=1, on revient exactement au modèle Lasso.

4.3.4 Réseaux de neurones :

4.3.4.1 Modèle réseau de neurones à une seule couche cachée :

Pour déterminer le nombre optimal de neurones dans la couche cachée, on teste plusieurs configurations en faisant varier ce nombre de 1 à 12. Pour chaque configuration, on entraîne le modèle et on réalise sa performance en calculant l'erreur quadratique moyenne (MSE) entre les valeurs réelles et les valeurs prédites. Enfin, on sélectionne le nombre de neurones qui correspondent à la MSE la plus faible, garantissant ainsi le meilleur compromis entre complexité et performance du modèle.

Cette figure illustre la variation de la MSE en fonction du nombre de neurones dans la couche cachée (MSE est multipliée par 10000) :




Figure 72 : Graphes MSE (multiplié par 10000) en fonction de nombre de neurones dans la couche cachée pour période 2

	NbrNeurones	mseNN2
3	3	2.697355
10	10	2.764888
9	9	2.870447
6	6	2.961164
7	7	3.041120
8	8	3.110281
12	12	3.247371
4	4	4.575299
11	11	4.646845
2	2	5.003334
1	1	5.063708
5	5	5.152968

Figure 73 : Tableau MSE (multipliée par 10000) pour chaque nombre de neurones cachés pour période 2

La MSE la plus faible correspond à trois neurones dans la couche cachée, cela signifie que le modèle atteint sa meilleure performance avec cette configuration.

Donc Les réseaux ayant trois neurones dans la couche cachée offrent les meilleurs résultats. Ainsi, le modèle retenu pour notre réseau de neurones comprend 6 neurones d'entrée, 3 neurones cachés et 1 neurone de sortie, comme présenté dans la figure suivante :




Figure 74 : Réseau de neurones d'une seule couche pour la période 2

Chaque variable est connectée aux 3 neurones cachés :

- Yield → Neurone caché 1 : -7.9496 → très fort impact négatif.
- VIX → Neurone caché 1 : $+2.1669$ → influence positive.
- Confidence → Neurone caché 3 : -0.95998 → influence négative.
- Cela montre que certaines variables, comme Yield ou VIX, dominent certaines parties du réseau.

De la couche cachée vers la sortie (Volatility)

- Neurone caché 1 → Volatility : -0.14405
- Neurone caché 2 → Volatility : $+0.49931$
- Neurone caché 3 → Volatility : -0.32081
- Ces poids indiquent l'effet final agrégé de chaque neurone sur la prédiction de la volatilité.

Ce réseau montre :

- Un fort effet non linéaire du Yield, avec un poids de -7.94 vers la couche cachée.
- Une influence directe du VIX sur le premier neurone, et donc sur la sortie.
- Des effets combinés complexes entre émotions, confiance et les autres variables économiques.

4.3.4.2 Réseau de neurones à deux couches cachées :

Pour déterminer le nombre optimal de neurones dans les deux couches cachées, on teste plusieurs configurations en faisant varier le nombre de neurones de 1 à 6 dans chaque couche (36 combinaisons obtenus). Pour chaque configuration, on entraîne le modèle et on évalue sa performance en calculant l'erreur quadratique moyenne (MSE) entre les valeurs réelles et les valeurs prédites. Enfin, on sélectionne la configuration avec le

nombre de neurones qui donne au MSE le plus faible, assurant ainsi un bon équilibre entre la complexité du modèle et sa performance.

Cette figure illustre la variation de la MSE en fonction du nombre de neurones dans les deux couches cachées pour les deux périodes étudiées (MSE est multipliée par 10000) :

**MSE en fonction du nombre de neurones cachés
1991-2024**




Figure 75 : Graphes MSE (multiplié par 10000) en fonction de nombre de neurones dans les deux couches cachées pour période 2

	NbrNeurones1	NbrNeurones2	mseNN2	CombinedLabels
4	1	4	2.670217	(1 , 4)
11	2	5	2.704220	(2 , 5)
19	4	1	2.715610	(4 , 1)
23	4	5	2.726899	(4 , 5)
36	6	6	2.749762	(6 , 6)
20	4	2	2.750506	(4 , 2)
12	2	6	2.782201	(2 , 6)
18	3	6	2.787831	(3 , 6)
16	3	4	2.798471	(3 , 4)
25	5	1	2.829372	(5 , 1)
34	6	4	2.832176	(6 , 4)
6	1	6	2.834565	(1 , 6)
29	5	5	2.835856	(5 , 5)

Figure 76 : Tableau MSE (multipliée par 10000) pour chaque nombre de neurones cachés pour période 2

La MSE la plus faible correspond à 1 neurone dans la première couche cachée et un 4 neurones dans la deuxième couche cachée, cela signifie que le modèle atteint sa meilleure performance avec cette configuration.

Donc les réseaux ayant 1 neurone dans la première couche cachée et 4 neurones dans la deuxième couche cachée offrent les meilleurs résultats. Ainsi, le modèle retenu pour notre réseau de neurones comprend 6 neurones d'entrée, (1,4) neurones cachés et 1 neurone de sortie, comme présenté dans la figure suivante :




Figure 77 : Réseau de neurones de deux couches cachées pour la période 1

- Toutes les variables d'entrée convergent vers un seul neurone, avec des poids :
 - InterestRate → Neurone 1 : +1.74
 - Confidence → Neurone 1 : -0.85
 - VIX → Neurone 1 : +0.59
- Le neurone unique envoie son signal à 4 neurones, avec des poids.
- Les 4 neurones de la deuxième couche sont connectés à la sortie, avec des poids.
- Ce réseau de neurones utilise une structure hiérarchique :
 - La première couche réduit toutes les entrées à un seul signal intermédiaire.
 - La seconde couche (4 neurones) en extrait des formes variées de non-linéarité.

Chapitre 5 : Comparaison des différents modèles utilisés :

5.1 Comparaison basée sur MSE :

	Modèles	MSE1	RMSE1	MSE2	RMSE2
1	ARIMA	0.000427199856290281	0.000206688136159355	0.000263756289580159	0.000162405754079145
2	ARIMA-EGARCH	0.000427175051729759	0.000206682135592256	0.000259933052082732	0.000161224393961563
3	Ridge	0.000204595846026667	0.000143037004312404	0.00048262123836112	0.000219686421601591
4	Lasso	0.000204594860816523	0.000143036659922036	0.000482354969328129	0.000219625811171667
5	ElasticNet	0.000204591668366799	0.000143035543962611	0.000482354969328129	0.000219625811171667
6	NN1	0.000205573005325103	0.000143378173138419	0.000269735531377862	0.000164236272296306
7	NN2	0.000200087341135221	0.0001414522326212	0.000267021720996257	0.000163407992765427

Figure 78 : Récapitulatif des modèles utilisés dans cette partie

- Sur les deux périodes, les modèles NN2 (réseaux de neurones profonds) offrent les meilleures performances globales, avec les plus faibles MSE et RMSE.
- Pour la période 2 (1991–2024) : Les variables émotionnelles et comportementales (VIX, Emotion, Confidence) sont incluses uniquement à cette période. Cela semble bénéficier aux modèles non linéaires comme les réseaux de neurones, qui capturent mieux les effets complexes que les modèles linéaires (Ridge, Lasso...).
- Les résultats montrent que les réseaux de neurones, en particulier NN2, surpassent systématiquement les autres modèles en termes d'erreur quadratique moyenne, notamment sur la période 1991–2024 où les variables émotionnelles (VIX, émotions, confiance) sont présentes.
- Cela confirme que les approches non linéaires sont mieux adaptées à la complexité comportementale des marchés récents, en capturant des relations plus subtiles entre les variables économiques et la volatilité.

5.2 Test de Diebold-Mariano :

Afin de comparer les performances prédictives de différents modèles, nous avons utilisé le test Diebold-Mariano (DM). Ce test permet de vérifier statistiquement si deux modèles ont des erreurs de prévision significativement différentes. Il est utilisé couramment pour évaluer la performance relative des modèles de prévision en fonction de la précision de leurs erreurs.

Une matrice des p-values a été créée pour stocker les résultats du test Diebold-Mariano. Cette matrice est carrée, avec des lignes et des colonnes représentant les modèles comparés. Chaque cellule de la matrice contient la p-value du test statistique pour la comparaison entre les erreurs des deux modèles correspondants.

Les p-values obtenues à partir du test Diebold-Mariano sont utilisées pour évaluer la performance comparative des modèles. Une p-value inférieure à un seuil de significativité de 0,05 suggère que les erreurs des deux modèles sont significativement

différentes, ce qui indique qu'un modèle peut être préféré à l'autre en termes de précision des prévisions. En revanche, une p-value élevée indique qu'il n'y a pas de différence significative entre les modèles.

- Période 1 :

	ARIMA	ARIMAEGARCH	Ridge	Lasso	ElasticNet	NN1	NN2
ARIMA	NA	9.919319e-01	1.254096e-01	1.255286e-01	1.224485e-01	1.546272e-06	5.052018e-07
ARIMAEGARCH	9.919319e-01	NA	1.226281e-01	1.227459e-01	1.196945e-01	1.489597e-06	4.931083e-07
Ridge	1.254096e-01	1.226281e-01	NA	4.495003e-03	7.282520e-03	6.669244e-11	1.093953e-09
Lasso	1.255286e-01	1.227459e-01	4.495003e-03	NA	6.803194e-03	6.676250e-11	1.094728e-09
ElasticNet	1.224485e-01	1.196945e-01	7.282520e-03	6.803194e-03	NA	6.616052e-11	1.084222e-09
NN1	1.546272e-06	1.489597e-06	6.669244e-11	6.676250e-11	6.616052e-11	NA	1.891907e-05
NN2	5.052018e-07	4.931083e-07	1.093953e-09	1.094728e-09	1.084222e-09	1.891907e-05	NA

Figure 79 : Test de Diebold-Mariano sur la première période

Les p-values très faibles indiquent que NN1 et NN2 surpassent significativement les autres modèles :

Exemples :

ARIMA vs NN1 : 1.546272e-06 → NN1 est bien meilleur qu'ARIMA.

ARIMA vs NN2 : 5.052018e-07 → NN2 est bien meilleur qu'ARIMA.

Ridge vs NN1 : 6.669244e-11 → NN1 est significativement meilleur que Ridge.

Lasso vs NN1 : 6.676250e-11 → NN1 est aussi meilleur que Lasso.

NN1 et NN2 sont clairement les meilleurs modèles, avec des p-values très faibles par rapport aux autres modèles.

- Période 2 :

	ARIMA	ARIMAEGARCH	Ridge	Lasso	ElasticNet	NN1	NN2
ARIMA	NA	0.1019535	0.3941796	0.3939874	0.3939874	0.8504047	0.9390150
ARIMAEGARCH	0.1019535	NA	0.3846766	0.3844689	0.3844689	0.8297739	0.9176165
Ridge	0.3941796	0.3846766	NA	0.6510965	0.6510965	0.3159015	0.2903111
Lasso	0.3939874	0.3844689	0.6510965	NA	NA	0.3151325	0.2895399
ElasticNet	0.3939874	0.3844689	0.6510965	NA	NA	0.3151325	0.2895399
NN1	0.8504047	0.8297739	0.3159015	0.3151325	0.3151325	NA	0.4811219
NN2	0.9390150	0.9176165	0.2903111	0.2895399	0.2895399	0.4811219	NA

Figure 80 : Test de Diebold-Mariano sur la première période

Les valeurs-p issues du test de Diebold-Mariano sur la période (1990–2024) indiquent qu'aucune des différences de performance entre les modèles testés n'est statistiquement significative à un seuil classique de 5 %. Autrement dit, le test ne permet pas de conclure qu'un modèle est supérieur aux autres sur la base de la précision de prévision des erreurs de volatilité.

Toutefois, cette absence de significativité doit être nuancée à la lumière de plusieurs éléments :

- Performances empiriques constantes du modèle NN2 : Le réseau de neurones NN2 présente systématiquement les meilleures erreurs quadratiques moyennes

(MSE et RMSE), ce qui indique une qualité prédictive supérieure dans les faits, même si cela n'est pas validé statistiquement.

- Sensibilité du test à la variance résiduelle : Le test DM repose sur des hypothèses fortes, notamment sur la stationnarité des erreurs et une variance constante. Or, les réseaux de neurones étant de nature stochastique, les erreurs peuvent présenter une variabilité résiduelle importante, réduisant la puissance du test.
- Échantillon réduit et présence de variables émotionnelles : Sur la période 1991–2024, le modèle intègre des variables nouvelles (VIX, sentiment, confiance), qui introduisent une complexité supplémentaire. Le test DM peut alors manquer de puissance pour capter les gains de précision qu'un modèle non linéaire comme NN2 sait exploiter.

5.3 Test de Clark & West sur la deuxième période :

Le test de Diebold-Mariano (DM) constitue un outil statistique classique pour comparer la performance prédictive de deux modèles. Il repose sur la comparaison des pertes de prévision (souvent les erreurs quadratiques) et teste l'hypothèse nulle d'égalité des capacités prédictives entre deux modèles. Toutefois, il présente une limite importante lorsqu'il s'agit de comparer un modèle de référence (benchmark), souvent simple et linéaire, à un modèle plus complexe, tel qu'un réseau de neurones.

Pour pallier cette limite, Clark & West (2007) ont proposé une version modifiée du test DM. Ce test repose sur une correction de l'erreur quadratique du modèle complexe afin de neutraliser le biais induit par la sur-paramétrisation. Concrètement, il ajuste la statistique de test de manière à mieux refléter la supériorité potentielle d'un modèle enrichi. Ainsi, le test de Clark & West permet de tester équitablement si un modèle complexe améliore significativement la prévision par rapport à un benchmark plus simple, sans être injustement défavorisé.

Ce test est effectué sur la deuxième période, nous a permis d'obtenir le résultat suivant :

	ARIMA	ARIMAEGARCH	Ridge	Lasso	ElasticNet	NN1	NN2
ARIMA	NA	0.05097676	0.8029102	0.8030063	0.8030063	0.5747976	0.5304925
ARIMAEGARCH	0.05097676	NA	0.8076617	0.8077655	0.8077655	0.5851131	0.5411917
Ridge	0.80291021	0.80766168	NA	0.3255483	0.3255483	0.1579508	0.1451555
Lasso	0.80300632	0.80776553	0.3255483	NA	NA	0.1575662	0.1447699
ElasticNet	0.80300632	0.80776553	0.3255483	NA	NA	0.1575662	0.1447699
NN1	0.57479763	0.58511307	0.1579508	0.1575662	0.1575662	NA	0.2405609
NN2	0.53049248	0.54119173	0.1451555	0.1447699	0.1447699	0.2405609	NA

Figure 81 : Test de Clark & West sur la période 2

Les valeurs-p des comparaisons de NN2 avec les autres modèles sont toutes inférieures à 0.25, et même < 0.15 face à Ridge, Lasso, ElasticNet :

- NN2 vs Ridge : 0.1451
- NN2 vs Lasso : 0.1448
- NN2 vs ElasticNet : 0.1447
- NN2 vs NN1 : 0.2406

Ce sont des niveaux faibles, indiquant une tendance claire en faveur de NN2, même si ce n'est pas encore au seuil classique de 5 %, contrairement à la première période.

Les résultats montrent que les valeurs-p des comparaisons entre NN2 et les modèles linéaires (Ridge, Lasso, ElasticNet) sont systématiquement inférieures à 0.15, ce qui révèle une tendance significative à la supériorité du modèle NN2. Même si le seuil de significativité de 5 % n'est pas formellement atteint, ces résultats renforcent l'idée que NN2 capte mieux la complexité structurelle et émotionnelle du marché dans un environnement moderne.

Conclusion :

Ce mémoire avait pour objectif d'explorer les capacités prédictives de différents modèles économétriques et d'apprentissage automatique dans l'estimation de la volatilité des marchés financiers. Deux périodes distinctes ont été analysées : une première, historique (1881–1990), basée uniquement sur des variables fondamentales classiques, et une seconde (1991–2024), intégrant des variables additionnelles à forte composante comportementale, telles que l'indice VIX, le sentiment des investisseurs et l'indice de confiance.

Les résultats empiriques, mesurés à travers les métriques d'erreur classiques (MSE et RMSE), indiquent que les réseaux de neurones profonds, en particulier le modèle NN2 (à 2 couches cachées), surpassent globalement les autres approches, notamment dans la seconde période, où la richesse explicative des données est plus grande. Cette observation suggère que la présence de variables émotionnelles et comportementales renforce la pertinence des modèles non linéaires et flexibles, capables de mieux capter des dynamiques complexes difficilement modélisables par des approches traditionnelles.

D'un point de vue statistique, le test de Diebold-Mariano n'a pas permis de dégager de différences significatives entre les modèles, probablement en raison de la proximité des erreurs moyennes et des limites du test dans un contexte de forte hétérogénéité structurelle entre les modèles. En revanche, le test de Clark & West, plus adapté à la comparaison entre un modèle de référence et un modèle enrichi, a mis en évidence une tendance constante en faveur du modèle NN2, sans toutefois atteindre systématiquement les seuils de significativité attendus.

Ces résultats révèlent une évolution importante : plus on se rapproche de la période récente, plus les facteurs comportementaux semblent jouer un rôle central dans la dynamique de la volatilité. Ils soulignent également l'intérêt d'utiliser des modèles de Machine Learning dans un contexte financier moderne, où les interactions entre fondamentaux, politiques monétaires et émotions des investisseurs deviennent de plus en plus imbriquées.

En somme, si aucun modèle ne domine statistiquement de manière absolue selon tous les tests, les réseaux de neurones apparaissent comme les plus prometteurs pour la prévision de la volatilité, en particulier dans des environnements complexes où les dimensions émotionnelles et psychologiques du marché sont prises en compte.

Ouverture :

Ce travail soulève par ailleurs une perspective de recherche stimulante : au-delà de la performance empirique, quels sont les fondements mathématiques et structurels qui expliquent la capacité des réseaux de neurones à surpasser les modèles classiques dans un contexte financier ?

Une étude plus approfondie de l'architecture des réseaux, de leurs fonctions d'activation, des méthodes de régularisation ou encore des dynamiques d'optimisation pourrait faire l'objet d'un futur travail doctoral, visant à mieux comprendre les mécanismes internes qui rendent ces modèles efficaces et à concevoir des architectures encore plus adaptées aux spécificités des données financières.

Bibliographie :

[1] Robert J. Shiller ; « Market Volatility » ; 30 Janvier 1992

[2] David Bourghelle, Fredj Jawadi et Philippe Rozin ; « Do collective emotions drive bitcoin volatility? A triple regime-switching vector approach » ; 24 Février 2022

[3] David Bourghelle, Fredj Jawadi et Philippe Rozin ; « Can Collective Emotions Improve Bitcoin Volatility Forecasts? » ; 24 Février 2022

[4] Vineet Agarwal, Richard J. Taffler et Chenyang Wang ; « How emotional is the stock market? An empirical analysis » ; 19 Janvier 2024

[5] Ancien cours de Youssef Lamrani Alaoui « Maître de conférences à l'Ecole Mohammadia d'Ingénieurs »